

分 类 号 TP391.9

学 号 22212060952

密 级 无



西安石油大学
Xi'an Shiyou University

全 日 制 专 业 学 位

硕 士 学 位 论 文

题 目 基于时空图卷积神经网络的智能交通预测

方法研究

论 文 作 者 张文雨

指 导 教 师 郑凯东

专业、领域名称 计算机技术

提交论文时间 2025 年 5 月 25 日

论文题目：基于时空图卷积神经网络的智能交通预测方法研究

专 业：计算机技术

硕 士 生：张文雨(签名) _____

导 师：郑凯东(签名) _____

摘 要

在智能交通系统不断发展的背景下，交通预测作为实现智能交通系统高效运行的关键技术，正受到广泛关注。然而，由于交通数据具有高度的时空相关性与动态不确定性，如何精准捕捉其演变规律并有效反映预测结果中的不确定性成为了交通预测任务中亟待解决的挑战。针对现有方法的局限性，本文结合交通领域知识与先进的深度学习技术，分别从提升预测精度和增强不确定性建模能力两个方面对智能交通预测方法进行研究。一方面，研究中针对交通数据的复杂时空特性，提出新型建模方法以提高交通预测的准确性；另一方面，面向交通数据中的不确定性问题，探索引入扩散模型等生成式建模思路，以实现对未来交通状态不确定性的有效刻画，主要工作如下：

(1) 为了充分考虑不同的交通数据特性，提出了一种基于多分量时序图神经网络模型，简称为 MTGNN。首先，该模型通过季节趋势分解对交通序列进行结构化预处理得到季节项和趋势项。其次，分别对季节项与趋势项建模时空相关性。具体地，在时间相关性建模中，模型分别利用频域注意力网络和时间卷积网络对季节项和趋势项建模时间依赖性；在空间相关性建模中，两项均采用改进后的图注意力机制建模空间依赖性。最后，在得到两项不同预测输出的同时，进行输出融合操作，得到最终预测结果。实验结果验证了 MTGNN 模型在预测精度与稳定性方面的优越表现。

(2) 为了更好地刻画交通预测中的不确定性，进一步提出了一种基于扩散过程的时空小波模型，简称为 DiffSTWave。该模型在原始扩散模型中引入了图结构、时间步与历史信息作为先验条件，并在反向生成阶段设计了去噪网络，从而构建了一个交通任务专用的条件扩散框架，更有效地刻画了复杂交通预测中的不确定性分布。其中，去噪网络通过离散小波变换实现高低频信息的分离解耦，并利用设计的时空块分别捕捉高低频数据中的时空相关性。实验结果表明 DiffSTWave 模型实现了更为可信的置信区间估计，在预测突发事件和异常状态时具备更强的鲁棒性和适应能力。

关键词：深度学习；交通预测；扩散模型；离散小波变换；图神经网络

论文类型：应用研究

Subject : Research on Intelligent Traffic Prediction Method Based on Spatio-Temporal Graph Convolutional Neural Networks

Speciality : Computer Technology

Name : Zhang Wenyu (signature)_____

Instructor: Zheng Kaidong (signature)_____

ABSTRACT

In the context of the continuous development of intelligent transportation systems (ITS), traffic prediction, as a key technology to realize the efficient operation of ITS, is receiving extensive attention. However, due to the high spatio-temporal correlation and dynamic uncertainty of traffic data, how to accurately capture its evolution pattern and effectively reflect the uncertainty in the prediction results has become a challenge to be solved in the task of traffic prediction. Aiming at the limitations of the existing methods, this paper combines the knowledge of the traffic domain with advanced deep learning techniques to investigate the intelligent traffic prediction methods from the aspects of improving the prediction accuracy and enhancing the uncertainty modeling capability, respectively. On the one hand, the study proposes new modeling methods to improve the accuracy of traffic prediction with respect to the complex spatio-temporal characteristics of traffic data; on the other hand, the study explores the introduction of generative modeling ideas, such as diffusion models, to achieve effective portrayal of uncertainty in future traffic states with respect to the uncertainty in traffic data, and the main work is as follows:

(1) In order to fully consider different traffic data characteristics, a multi-component time-sequence graph neural network model based on multi-component time-sequence graph neural network model, abbreviated as MTGNN, is proposed. Firstly, the model preprocesses traffic sequences structurally through seasonal trend decomposition to obtain seasonal terms and trend terms. Second, temporal correlations are modeled for the seasonal and trend terms, respectively. Specifically, in the temporal correlation modeling, the model models the temporal dependence of the seasonal and trend terms using frequency-domain attention network and temporal convolutional network, respectively; in the spatial correlation modeling, both models use the improved graph attention mechanism to model the spatial dependence. Finally, while obtaining two different prediction outputs, the output fusion operation is performed to obtain the final prediction results. The experimental results verify the superior performance of the MTGNN in

terms of prediction accuracy and stability.

(2) In order to better portray the uncertainty in traffic prediction, a spatio-temporal wavelet model based on the diffusion process, referred to as DiffSTWave, is further proposed, which introduces the graph structure, time-step and historical information as a priori conditions in the original diffusion model, and designs the denoising network in the inverse generation stage, thus constructing a conditional diffusion framework specific to the transportation task. framework, which more effectively portrays the uncertainty distribution in complex traffic prediction. Among them, the denoising network realizes the separation and decoupling of high and low-frequency information through the discrete wavelet transform, and utilizes the designed spatio-temporal blocks to capture the spatio-temporal correlations in the high and low-frequency data, respectively. The experimental results show that the DiffSTWave achieves more plausible confidence interval estimation, and possesses stronger robustness and adaptability in predicting unexpected events and abnormal states.

Keywords: Deep Learning; Traffic Prediction; Diffusion Model; Discrete Wavelet Transform; Graph Neural Network

Paper Type: Applied Research

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状与进展.....	2
1.2.1 交通预测的确定性方法.....	3
1.2.2 交通预测的不确定性方法.....	6
1.3 论文研究内容.....	8
1.4 论文组织框架.....	8
第二章 基础理论及相关技术	11
2.1 交通流概念理论.....	11
2.1.1 交通流数据.....	11
2.1.2 交通数据特性.....	12
2.2 时空数据建模方法.....	14
2.2.1 时间相关性建模方法.....	14
2.2.2 空间相关性建模方法.....	17
2.3 扩散模型基础理论.....	18
2.3.1 前向过程.....	18
2.3.2 反向过程.....	19
2.3.3 去噪网络.....	20
2.4 总结.....	20
第三章 基于多分量时序图神经网络的交通预测方法	22
3.1 引言.....	22
3.2 交通预测问题定义.....	23
3.3 多分量时序图神经网络模型	23
3.3.1 模型框架.....	23
3.3.2 数据分解模块.....	24
3.3.3 时空建模模块.....	25
3.3.4 数据融合与预测.....	28
3.4 实验设计与结果分析.....	28
3.4.1 实验相关设置.....	28
3.4.2 实验一：MTGNN 模型与经典预测模型的精度对比实验...30	
3.4.3 实验二：MTGNN 模型的超参数实验.....	33
3.4.4 实验三：MTGNN 模型的消融实验.....	34
3.5 总结.....	35
第四章 基于扩散模型的交通预测方法	37

4.1 引言.....	37
4.2 基于扩散过程的时空小波模型	38
4.2.1 模型框架.....	38
4.2.2 去噪网络模块.....	40
4.2.3 数据分解模块.....	41
4.2.4 时空建模模块.....	42
4.2.5 噪声等级嵌入.....	44
4.2.6 噪声融合和预测.....	45
4.3 实验设计与结果分析.....	45
4.3.1 实验相关设置.....	45
4.3.2 实验一：DiffSTWave 模型与经典预测模型的精度对比实验	47
4.3.3 实验二：DiffSTWave 模型的超参数实验	49
4.3.4 实验三：DiffSTWave 模型的消融实验	50
4.3.5 实验四：DiffSTWave 模型的交通预测曲线对比展示	52
4.4 本章小结.....	54
第五章 总结与展望	55
5.1 总结.....	55
5.2 展望.....	56
参考文献.....	58

第一章 绪论

智能交通预测是智慧交通系统的重要组成部分，能够有效缓解交通拥堵，提高出行效率。本章将对交通预测的研究背景和意义进行详细阐述，系统梳理国内外在该领域的研究现状，分析现有方法的优势与不足，为后续研究奠定理论基础。同时，本章还将明确本研究的主要目标，概述研究内容和组织框架，为后续章节的展开提供支撑。

1.1 研究背景及意义

随着城市化进程的加快和人口的急剧增加，我国的机动车数量和交通流量开始迅速增长，交通情况也变得愈发复杂。据公安部^[1]统计，2024 年全国新注册登记机动车 3583 万辆，比 2023 年增加 104 万辆，增长 2.98%。其中，新注册登记汽车 2690 万辆，比 2023 年增加 234 万辆，增长 9.53%，自 2015 年以来已连续 10 年新注册登记量超过 3000 万辆。随着机动车数量的不断增加，交通压力也在持续加大，交通拥堵已成为各大城市普遍面临且亟须解决的问题。交通拥堵不仅对民众的日常出行造成了不便，在其他方面，例如城市的经济发展、环境保护以及社会稳定等，也造成了深远的影响。

为了解决交通拥堵问题，我国不断加强基础设施建设，并促进综合立体交通网加速成型，在持续优化交通基础设施网络结构的同时，积极发展完善交通网络。在党的十九大报告中，首次提出建设交通强国，随后党的二十大报告中同样强调要加快建设交通强国，这都为新时代交通运输高质量发展指明了方向。如图 1-1 所示，截止 2023 年^[2]，全国公路里程 543.68 万公里，比上年末增加 8.20 万公里。公路密度 56.63 公里/百平方公里，增加 0.85 公里/百平方公里。同时，城市轨道交通建设也在稳步推进，截至 2023 年底，全国共有 54 个城市开通城市轨道交通，运营里程达到 10945.6 公里。




图 1-1 2019 年-2023 年末全国公路里程与密度图

交通网络基础设施的不断完善为缓解城市交通压力提供了基本保障，但面对日益复杂的交通态势，单靠增加道路供给已难以彻底解决交通拥堵问题。数据显示^[3]，2023 年百城中 86%的城市 2023 年度通勤高峰交通拥堵指数同比 2022 年上涨，平均涨幅为 7.17%，

最大涨幅为 26.92%。在交通需求不断增长的背景下,仅依靠传统的交通供给手段已无法有效应对交通拥堵带来的挑战。为了解决这一日益严重的挑战,智能交通系统(Intelligent Transportation System, ITS)^[4]应运而生。智能交通系统通过信息技术、人工智能和大数据分析等先进手段,实现交通系统的自动化、智能化和高效化,为城市交通管理提供科学的决策支持。其中,交通预测作为智能交通系统中的一项关键技术,能够通过分析交通流量数据、交通模式和未来趋势,为交通管理部门提供实时、精准的交通预测结果。交通预测不仅可以提前识别潜在的拥堵点,帮助城市交通管理部门制定相应的缓解措施,还可以动态优化交通信号灯的时序、调整公交线路、规划新的道路建设项目等,从而有效提升城市交通的运行效率^[5]。此外,准确的交通预测还可以为居民的出行提供科学的决策支持,帮助他们选择最佳的出行时间和路线,避免拥堵,提高出行效率^[6]。因此,交通预测对城市交通管理、交通规划以及居民出行体验具有非常重要的意义。

在交通预测领域中,传统的预测模型主要基于经典的统计模型和机器学习方法,这些方法虽然在一定程度上能够捕捉交通流的规律性,但是无法应对紧急突发交通事件以及其他复杂的交通情况。一方面,这些方法往往难以捕捉交通数据中复杂的时空相关性;另一方面,这些方法对数据的假设较多,缺乏对不确定性的量化能力,这在实际应用中可能导致预测结果的失真和不稳定。为了应对这些困难,研究者们开始转向基于深度学习的交通预测方法。近年来,深度学习和人工智能技术快速发展,已经在图像识别、语音处理、自然语言处理等多个领域中均取得了突破性的研究成果,展现出强大的特征表示能力与建模复杂系统的潜力。这些优势也正在深刻地改变时空预测领域的研究范式。

在交通预测任务中,基于深度学习的交通预测方法通过对大量历史交通数据的学习,能够自动提取高维特征,捕捉数据中的复杂模式,从而提高预测的准确性与鲁棒性。同时,深度学习模型凭借其强大的特征提取与表示能力,能够有效扩展至大规模、复杂的交通网络,适应实际应用中存在的多样化场景需求。因此,探索新型的交通预测模型,不仅能够在提升预测精度方面取得更大进展,还可以在应对突发事件、缓解数据缺失影响、适应交通网络结构动态变化等方面开辟新的研究路径。这对于推动智能交通系统的发展、实现更高效、更智能的出行规划具有重要意义。

本论文聚焦于深度学习交通预测方法,通过构建能够有效捕捉复杂时空特征、保证预测稳定性与可靠性的深度学习模型,为智能交通系统的构建提供理论依据与技术参考,具有重要的实际应用价值。

1.2 国内外研究现状与进展

近年来,随着多源异构交通数据的涌现和数据获取方式的多样化,交通预测方法的研究已进入新的阶段。从单一的数据源到多模态数据的融合,从传统的时序建模到深度学习驱动的时空建模,研究者们正致力于构建更具泛化能力的交通预测模型。国内外相

关研究围绕交通预测的不同维度展开,包括交通传播流预测^[7]、交通噪声预测^[8]、区域性交通状态预测^[9]以及异常事件下的交通预测^[10]。其中,交通流量预测因其在交通信号控制、道路调度和应急响应等方面的重要作用,成为研究的重点方向。本文研究的交通预测问题,具体指交通流量预测,旨在探索更精准、高效的建模方法,以应对复杂交通环境下的预测需求。

随着研究的深入,交通预测方法逐渐分化为确定性方法和不确定性方法两个主要方向。确定性方法主要针对交通流量的固定趋势建模,试图通过建模历史数据中的时空模式来获得唯一的预测结果,适用于对交通状态进行快速判断和短期优化。与之相对应,不确定性方法通过引入概率建模和贝叶斯推断等策略,能够捕捉交通流量中的随机性和潜在风险,为交通管理部门提供更加稳健和灵活的决策依据。因此,系统分析这两类方法的发展现状、优缺点及其在不同场景中的适用性,不仅有助于更好地理解交通预测领域的前沿进展,也为构建更具适应性和可靠性的交通预测模型奠定基础。

基于此,本节将系统梳理国内外交通预测方法的研究现状与进展,并重点分析确定性方法与不确定性方法的发展与应用。

1.2.1 交通预测的确定性方法

交通预测的确定性方法在交通流量预测中占据重要地位,通常通过建立明确的数学模型来描述交通流量的演变规律。这些方法假设交通数据的变化可以通过历史数据中的时空模式进行建模,并生成一个固定的预测结果,为交通管理和调度提供直接的决策依据。随着数据量的不断增加和数据特征的日益复杂,各种各样的数据驱动方法被提出以高效预测交通流量,这些方法大致可以分为经典统计方法和机器学习方法两个主要类别。

(1) 经典统计方法

从城市路网短时流量预测到轨道交通客流长期规划,经典统计方法凭借其低计算成本与高可解释性,成为交通管理部门早期决策的重要工具。经典统计方法通过分析和推断数据中不同变量的关系,以期刻画时序规律。具有代表性的模型有整合移动平均自回归模型(AutoRegressive Integrated Moving Average, ARIMA),卡尔曼滤波模型(Kalman Filtering)和线性回归模型(Linear Regression)等。此类模型虽假设误差项或状态的分布特性,但在实际交通预测中常被简化为确定性工具,仅输出均值的预测值。

近年来,研究者们通过改进这些经典统计模型,进一步提升了它们在交通流量预测中的应用效果。例如,Miao 等人^[11]提出了一个名为 ESARIMA 的模型,以提高 ARIMA 模型在预测交通流量时的效率和准确性。Chang 等人^[12]提出了一种新的张量扩展卡尔曼滤波器方法,以适应任意张量形式的任意输入、输出和状态变量。Rajeh 等人^[13]将交通流量预测问题转换为多元线性回归问题,直接从邻居节点的流量中预测未来的流量,克服了曝光偏差问题。

尽管这些统计方法在某些场景中表现良好，但它们通常依赖于有限的历史数据，无法充分捕捉交通流量数据中复杂的非线性动态特征。例如，ARIMA 模型擅长处理线性时间序列数据，但面对复杂的非线性依赖关系时，其性能可能会显著下降。同样，卡尔曼滤波在估计状态变量方面表现优异，但当面对交通流量中的非线性动态变化时，其估计精度也会受到限制。线性回归依赖于固定的线性权重对输入特征进行加权求和，无法自适应不同时间段的流量模式变化，导致在高峰期和低谷期的预测偏差较大。

总的来说，虽然统计方法在理论上提供了坚实的基础，并在一定程度上解决了交通预测问题，但面对日益复杂的交通网络和数据特征，这些方法逐渐显现出局限性，难以满足实际应用中的需求。因此，越来越多的研究开始转向非线性建模能力更强的机器学习方法，以进一步提升交通预测的效果。

（2）机器学习方法

为了应对交通数据响应于各种因素的变化，解决交通预测的非线性问题，机器学习方法逐渐成为研究的焦点。传统的机器学习方法，例如 k 阶最近邻 (k-Nearest Neighbors, KNN)^[14] 和支持向量机 (Support Vector Machine, SVM)^[15]，在早期交通预测任务中得到了广泛应用。KNN 通过基于距离的相似性度量来预测未来流量，适用于简单的线性或局部模式识别，而 SVM 则利用核函数将数据映射到高维空间，能够较好地捕捉到一些非线性关系。因此，这些方法在一些简单的交通流预测任务中表现较好，尤其是在数据量较小且模式较为简单的情况下。

然而，随着交通网络的日益复杂化和交通数据量的迅速增长，这些传统方法的局限性逐渐显现。首先，KNN 和 SVM 在面对大规模、复杂的时空交通数据时，计算效率和泛化能力存在明显瓶颈。KNN 的计算开销较大，尤其是在数据集庞大时，需要频繁计算每对样本之间的距离，这导致其在实时交通预测中的应用受到限制。SVM 虽然能够处理一些非线性问题，但其对大规模数据集的处理能力较弱，训练过程的计算开销非常高。其次，传统方法难以捕捉交通流量的长期依赖性以及时序数据中的动态变化规律。为此，研究者们引入了更加高效的深度学习模型，以实现交通预测领域的革新。

其中，循环神经网络 (Recurrent Neural Network, RNN)，长短时记忆网络 (Long Short-Term Memory, LSTM) 和门控循环单元 (Gate Recurrent Unit, GRU) 等是交通预测任务中最常用的时序建模方法。RNN 模型利用循环结构，能够有效捕获交通数据中的短期时间相关性，在处理时序预测任务上具有天然优势。Yuan 等人在文章中^[16]总结了基于 RNN 模型的时空序列预测算法，尤其是交通流预测算法，并探讨了不同算法的优缺点；温等人^[17]利用循环神经网络实现对未安装车流量检测设备的高速公路路段进行短时交通量准确预测。

然而，由于梯度消失和梯度爆炸问题，RNN 模型在捕捉长期依赖性时表现有限。为了解决这一问题，LSTM 和 GRU 模型被提出。LSTM 模型通过引入记忆单元和门控机制，能够有效存储和传递长期信息，从而显著提高了对复杂时序数据的建模能力。

Ounoughi 等人^[18]构建了基于长短时记忆网络的双向堆栈层,有效地揭示交通数据中固有的时间依赖;Raut 等人^[19]利用基于自适应网格搜索的粒子群优化算法对长短时记忆模型的超参数进行优化,进一步提升了短期交通预测模型的性能。GRU 则是 LSTM 的简化版本,通过减少参数数量,在模型性能和计算效率之间达到了更好的平衡。Bhaumik 等人^[20]设计了一种基于轻量级门控循环单元的新型交通预测模型;Zhang 等人^[21]利用时空双向门控循环单元耦合当前时间步和后向信息来学习交通数据中的时空信息。

在实际应用中,研究者们尝试将这些基础时序预测模型进行组合或进行改进优化,以充分发挥各自的优势。例如,Lv 等人^[22]将 RNN 和 GRU 有机结合,利用模型捕获时间相关性;Harrou 等人^[23]将 LSTM 和 GRU 与多尺度去噪相结合以预测道路交通流。这种多模型结合的方法在实际交通预测任务中表现出色,显著提升了预测精度和鲁棒性。

总之,深度学习方法的引入为交通预测领域带来了革命性的变化。通过合理设计和优化模型结构,这些方法不仅能够捕捉复杂的非线性特征,还为交通流量的动态建模提供了更多可能性。尽管时序预测方法在捕捉交通流量的时间相关性方面表现出了良好的性能,但如果不去充分考虑交通路网中的空间结构信息,而是假设不同道路上的传感器节点是相互独立的数据流,可能会导致模型在复杂城市路网中的预测性能显著下降。

交通数据天然包含着显著的空间依赖性,例如相邻道路的车流量往往相互影响,拥堵情况也可能沿特定路段扩散。因此,忽略这些空间特征会限制模型的预测能力和泛化性能。在深度学习中,卷积神经网络(Convolution Neural Network, CNN)被初步引入以捕捉此类空间依赖性,其通过局部感受野和权值共享机制,能够从规则的网格化数据中提取邻近区域的潜在空间关联。例如,李等人^[24]使用卷积神经网络提取基于网格划分的城市区域交通数据的空间特征,对城市区域短时交通拥堵情况进行预测。

然而,传统 CNN 的局限性在于其假设数据具有欧几里得空间结构,而真实交通路网的拓扑关系往往呈现非欧几里得特性,导致模型难以有效建模长距离依赖与动态拥堵传播路径。为了解决这一问题,图神经网络(Graph Neural Network, GNN)^[25]被引入到交通预测领域,用于建模交通路网这种离散且非规则排列的非欧几里得结构。图神经网络通过处理节点与边的关系,可以直接对图结构数据进行高效的特征提取,捕捉复杂的空间拓扑特性。这种能力使 GNN 成为建模交通数据空间依赖性的理想选择。

为了进一步增强交通预测的精确性,研究者们尝试将图神经网络与时序预测方法相结合,构建时空图模型,从而同时捕捉交通流量的空间和时间依赖性。这种方法通过在图的节点中嵌入时间维度,不仅能够建模交通路网的拓扑结构,还可以分析其动态变化特征。Zhao 等人^[26]提出 T-GCN,该模型通过结合图卷积网络(Graph Convolutional Network, GCN)和门控循环单元,实现了对交通路网的复杂拓扑结构和动态时间特性的联合建模,这一框架在多个交通流量预测任务中表现出较高的预测精度,验证了同时建模空间和时间依赖性的有效性。Wu 等人^[27]提出了 Graph WaveNet,它通过创新地结合图卷积网络和膨胀因果卷积(Dilation Causal Convolution),显著增强了模型的时空特征提取能力。Zheng

等人^[28]提出了时空图常微分方程网络 STGODE，它通过张量形式的图神经网络连续表示法，突破网络深度的限制，提高了提取更长距离时空相关性的能力。

图神经网络的引入极大地拓展了交通预测模型的能力，使得建模复杂路网结构成为可能。通过与时序预测方法的结合，这类方法实现了对交通流量时空特性的综合建模，在多个较为稳定的应用场景中展现出了显著的性能优势。然而，如何提高应对交通预测中的不确定性，依然是未来研究的重点方向。这些努力将为实现更加智能和可靠的交通预测奠定基础。

1.2.2 交通预测的不确定性方法

尽管确定性方法在稳定条件下表现出色，但在实际场景中，交通流量常因事故、突发事件或其他不可预测的因素而在短时间内发生剧烈波动。这种动态性与不确定性为交通预测模型提出了新的挑战，即如何对未来交通系统的潜在不确定性进行建模，从而提供更具弹性的预测结果。为了解决这一问题，研究者们逐渐转向基于概率方法的建模技术，如图 1-2 所示，概率方法可以通过对未来时序数据的概率分布进行采样，从而生成更好的未来序列。与确定性方法相比，概率方法能够捕捉数据中的复杂模式，同时提供未来预测的不确定性量化信息，显著提升了预测的可靠性与鲁棒性。




图 1-2 概率方法优越性

概率方法的核心思想是将交通流量视为一个随机过程，模型不仅预测未来的期望值，还可以通过学习数据的潜在分布，对未来时序数据的不同可能性进行建模。这种方法通常采用贝叶斯框架、基于不确定性量化的神经网络或深度生成模型来实现。其中，贝叶斯线性回归 (Bayesian Linear Regression)^[29]、高斯过程回归 (Gaussian Process Regression, GPR)^[30]等传统概率模型能够在预测时直接给出预测均值和方差，刻画未来交通流量的不确定性。然而，这类方法计算复杂度较高，难以在大规模交通数据中高效应用。

近年来，基于不确定性量化的神经网络如贝叶斯神经网络 (Bayesian Neural Network,

BNN)^[31]和蒙特卡洛 Dropout (MC-Dropout)^[32], 通过在模型权重或神经网络结构上引入随机性, 使得每次预测均可生成不同的样本, 实现对未来交通状态的概率预测。这类方法不仅提供了预测结果的均值, 还能生成预测分布, 从而量化未来交通状态的置信区间, 有效提升了模型的鲁棒性和可靠性。

此外, 深度生成模型在交通预测中的应用日益增多, 尤其是变分自编码器 (Variational Autoencoder, VAE)^[33]、生成对抗网络 (Generative Adversarial Network, GAN)^[34]以及扩散模型 (Diffusion Models)^[35]等方法, 能够在大规模数据中有效学习数据分布, 并生成具有多样性的未来序列。在众多概率方法中, 扩散模型因其强大的表达能力而备受关注。本论文主要介绍去噪扩散概率模型 (Denoising Diffusion Probabilistic Model, DDPM)^[36]及其变体, 如无特别说明, 提到的扩散模型均指代此类方法。扩散模型作为一种新兴的生成模型, 能够通过逐步引入噪声并逆向还原的过程, 生成符合真实数据分布的样本, 从而在捕捉交通流量复杂模式的同时提供不确定性量化信息。

作为目前最流行的概率模型之一, DDPM 的核心思想是通过一系列逐步去噪的过程, 将初始的纯白噪声逐步转化为与真实数据分布一致的样本。这种生成式建模方法不仅在计算机视觉 (Computer Vision, CV)^{[37][38][39]}和自然语言处理 (Natural Language Processing, NLP)^{[40][41]}领域取得了巨大成功, 也在时间序列预测领域展现出广阔的应用前景, 特别是在多变量预测、缺失值填补以及生成建模等任务中, 多个创新性方法表现出优越的性能。例如, Rasul 等人^[42]提出了 TimeGrad 模型, 一种基于扩散模型的自回归方法, 用于解决多变量时间序列的概率预测问题。该模型借助 Langevin 采样机制在推理阶段逐步将噪声转化为有效的预测值, 从而结合了扩散模型的灵活性与自回归建模的时序特性。针对时间序列中的缺失值填补问题, Tashiro 等人^[43]提出了 CSDI 模型。该模型采用条件分数匹配的扩散机制, 显式利用已观测数据作为条件进行建模, 并通过自监督的方式进行训练, 有效挖掘观测值之间的时空相关性。此外, Yuan 等人^[44]设计了 Diffusion-TS 模型, 一个结合变换器结构与扩散模型的时间序列生成框架。该模型在训练中直接重构样本而非噪声, 辅以基于傅里叶变换的损失函数, 提高生成序列的可解释性与真实性。

同时, 扩散模型的研究进一步拓展至时空图预测领域, 针对交通数据的时空依赖性提出了一系列创新性方法。例如, Wen 等人^[45]提出了一个条件去噪模型 DiffSTG, 并且设计了一个去噪网络 UGnet, 该网络能够有效地模拟数据中的时空依赖性, 从而执行有效的去噪。通过融合空间与时间信息, DiffSTG 在复杂交通场景中展现出了优越的预测性能。Zhang 等人^[46]开发了一种自适应噪声标度扩散模型 SaSDim, 该模型提出了一种新的损失函数, 能够将噪声缩放至相似的强度, 从而更高效地处理空间时间序列插值问题。这种机制显著提高了模型在数据恢复和预测任务中的表现。Hu 等人^[47]提出了一种统一的时空扩散模型 (Unified Spatial-Temporal Diffusion, USTD), 其中预处理模块被设计为编码器, 用于提取时空特征, 而轻量级解码器负责对数据进行重构。这一模型通过集成扩散过程与编码器-解码器架构, 进一步提升了对复杂交通流量的建模能力。

新型的扩散模型通过引入概率性和逐步扩散过程，不仅有效提高了对复杂时空数据的预测准确性，同时增强了模型的鲁棒性和可靠性。这些方法为交通预测提供了更为全面和可靠的工具，特别是在应对交通数据中的非线性特性和不确定性方面，展现出了巨大的应用潜力。

1.3 论文研究内容

考虑到在真实的交通预测任务中，交通路网中通常存在两种不同的交通模式：一种是在城市主干道上相对稳定的交通模式，另一种是在交通事故多发、交通状态波动较大路段的交通模式。确定性建模可以有效地捕捉稳定交通模式中的周期性，而不确定性建模可以对不稳定交通模式进行不确定性量化。基于此，本文针对确定性建模和不确定性建模两条路径分别开展研究，旨在突破复杂交通预测任务中对时空依赖建模和不确定性建模的双重挑战，构建更为准确与可靠的交通预测模型。具体研究内容如下：

(1) 本文总结梳理了交通数据的特性，利用其往往包含长期趋势性变化与周期性波动两类动态模式的特征，在数据预处理阶段，将交通序列分解为季节项和趋势项。为了识别解耦后两项数据中存在的不同动态模式，本文分别对其进行建模，使模型更专注地学习每种模式。季节项采用更擅长捕捉周期性的模型完成建模，趋势项则采用能够捕捉交通数据长期趋势的模型实现建模，从而避免不同成分之间的相互干扰，提高学习效果；同时，考虑到交通路网中传感器节点数量众多且图结构稀疏，传统图神经网络在全图建模中面临高计算成本的问题，本文对现有图神经网络结构进行优化，在保证建模能力的前提下有效降低计算复杂度。

(2) 为了更好地刻画交通数据的生成过程及其不确定性，本文引入了扩散概率模型，通过对数据进行扩散过程建模，将交通预测建模为一个从噪声向真实数据逐步演化的过程。与此前扩散模型直接对纯噪声进行降噪不同，本文设计了一种新的去噪网络，引入离散小波变换对噪声进行频域解耦，分别对高低频数据进行降噪。该去噪网络不仅能够提高高频成分中瞬时变化的预测精度，还使低频成分预测更加平稳准确。同时，在去噪过程中设计了一个全新的时空块，对数据中的时空相关性进行捕捉，使扩散模型能够更好地契合交通预测任务。通过上述设计，模型能够更好地还原数据的本质结构，提高去噪效果和学习能力，量化预测的不确定性，为决策者提供更为准确的风险评估，从而更好地应对交通预测中的动态变化与随机扰动。

1.4 论文组织框架

图 1-3 展示了本文的结构组织，全文主要内容安排如下：

第一章，绪论。首先介绍了交通流量预测的研究背景及其重要意义，分析了国内外相关研究的最新进展，重点讨论了时空建模和不确定性建模方面的研究现状。随后，针

对现有方法在复杂交通场景下的局限性进行了深入分析，明确了本文研究的问题和目标，对论文研究内容和组织框架进行了总结。




图 1-3 论文结构图

第二章，基础理论及相关技术。对交通流的基本概念和理论进行了阐述，并系统介绍了时空数据建模的相关方法。此外，还详细介绍了扩散模型的基本概念和在不确定性建模中的优势，为后续模型设计提供理论支持。

第三章，基于多分量时序图神经网络的交通预测方法。首先，分析了交通环境下对数据进行解耦的必要性，并阐述了交通预测的相关定义。紧接着，对基于多分量时序图神经网络的交通预测模型进行了介绍，该模型融合了时序数据解耦机制，旨在针对不同部分的数据特性，分别采用相应的时空模型，旨在更好地处理数据中的时空依赖。最后，详细说明了实验设计的具体流程，并对实验结果进行了详细说明与深入分析。

第四章，基于扩散模型的交通流量预测方法。首先，分析了传统扩散模型在交通预测中的局限性，并针对其不足之处，引入条件扩散机制，同时，提出了改进后的条件扩

散模型，并对其数学定义进行了详细阐述。随后，介绍了基于扩散过程的时空小波模型，该模型在反向去噪过程中引入了离散小波变换，对时空数据的高低频分解与建模。通过分别去噪，模型在反向生成数据时能够更准确地还原交通流量的时空特性。最后，通过实验评估验证了该模型的有效性，并对实验结果进行了深入分析和讨论。

第五章，总结与展望。首先，总结了本文提出的基于多分量时序图神经网络的交通预测方法和基于扩散模型的交通预测方法的研究成果，并分析了模型分别在捕捉时空特性和建模数据不确定性方面的优势。其次，根据模型的特性描述了相应的应用场景。最后，对未来可能的研究方向进行了展望，指出了可以在优化预测速度以及拓展模型应用场景方面进一步的探索。

第二章 基础理论及相关技术

本章主要介绍交通预测、时空相关性建模和扩散模型的基础理论以及相关技术。首先，详细阐述交通预测中的核心概念，特别是交通流数据的关键指标交通流量，并提出交通数据的特性，为后续模型设计奠定理论基础。随后，分别展开叙述时间相关性建模方法和空间相关性建模方法，分析他们在交通预测中的作用。最后，详细说明扩散模型的基本原理，并给出具体步骤及相关数学公式。

2.1 交通流概念理论

2.1.1 交通流数据

交通流数据^[48]是指反映道路交通状况的时空序列数据，通常由传感器、摄像头、GPS设备等多种数据源采集而得，是道路网络中车辆随时间和空间运动的总体表现。作为城市交通系统中最基本的研究对象，准确理解交通流的内在规律和数据特性，对于提高交通流预测模型的性能至关重要。交通流包含交通流量、速度、密度等核心指标，并可用于分析交通模式、预测未来交通状态，以及优化交通管理策略。交通流的变化受到多个因素影响，例如道路拓扑结构、交通信号控制、突发事件等，因此对交通流的建模需要综合考虑时间、空间和外部环境的复杂因素。从数学角度来看，交通流数据可以表示为一个时空序列，如式（2-1）所示。

$$X = \{X_t | t = 1, 2, \dots, T\} \quad (2-1)$$

其中， X_t 代表 t 时刻的交通状态，可以进一步细化为多个监测点的特征向量，如式（2-2）所示。

$$X_t = \{x_t^1, x_t^2, \dots, x_t^N\} \quad (2-2)$$

N 是交通传感器或路网节点的数量， x_t^i 代表第 i 个监测点在时间 t 的交通特征。

交通流量（Traffic Flow）是交通流在某一时空维度上的投影，指在单位时间内通过某一观测断面，如道路断面或交叉口的车辆数量，通常用符号 Q 表示。交通流量是衡量交通系统运行状态的重要指标，反映了道路在特定时间内所承载的交通需求，基本流量公式如式（2-3）所示。

$$Q = K \times V \quad (2-3)$$

其中， Q 是交通流量， K 是交通密度，即单位长度道路上的车辆数量， V 是平均车速，表示车辆在特定路段上的平均行驶速度。该公式表示交通流量与交通密度和平均车速之间的关系。当交通密度或平均速度变化时，交通流量也会相应变化^[49]。交通流量的变化可分为三个关键状态：自由流状态时，车速最高、交通密度最低，车辆可以顺畅通行；临界流量状态时，车速、密度和流量达到平衡，此时流量达到最大值；而在拥堵状态下，

交通密度过高，车速趋近于零，导致流量显著下降。这三种状态反映了交通系统从通畅到拥堵的动态变化过程，有助于理解和优化交通流特性。

2.1.2 交通数据特性

(1) 时空相关性：时空相关性^[50]指的是交通状态在时间和空间维度上的相互影响，即某条道路的交通状况不仅依赖于过去时刻的自身状态，还受到相邻道路及整个路网交通状况的影响。邻近依赖表现为相邻道路的交通状态直接影响彼此，例如主干道的拥堵可能导致支路流量减少，而全局依赖则体现为高速公路堵塞可能影响市区路网的流量，甚至改变跨区域的交通模式，如图 2-1 所示。




图 2-1 时空相关性中的邻近依赖

此外，由于道路系统的网络拓扑结构，交通数据的传播具有图结构特性，即道路可视为节点，交通数据作为边的权重，从而使得交通状态的变化受复杂网络拓扑约束。时空相关性不仅体现在时间或空间单独的维度上，还涉及两者的交互作用，例如突发事件会在时空维度上造成扩散效应，影响多个道路段并持续一段时间，信号灯控制、道路限行等交通管制措施也可能影响短期交通模式，并在高峰期引发更广泛的拥堵传播，如图 2-2 所示。



图 2-2 时空相关性中时空维度的扩散作用

为了更好地建模这些复杂的时空特性，时空图（Spatio-Temporal Graph, STG）被广泛应用于交通预测中。时空图通过将道路网络建模为图结构，其中节点表示道路或传感器位置，边表示道路之间的空间关联。结合时间序列信息，时空图能够有效捕捉交通流在时间和空间维度上的动态变化，为时空建模提供了坚实的理论基础，时空图示意图如图 2-3 所示。




图 2-3 时空图示意图

（2）周期性：周期性依赖^[51]主要反映在日周期和周周期的模式。日周期模式通常是由于早晚高峰的流量模式每天重复，如图 2-4 所示，节点的流量模式在 4 天内表现出明显的周期性特征。每天的流量趋势均呈现出早晚高峰的模式，且该模式在不同节点之间保持一致。在清晨 6 点至 9 点左右，流量迅速上升，达到第一个流量峰值，随后在中午到下午时段逐渐回落。晚高峰通常出现在 16 点至 19 点之间，流量再次攀升并在夜晚逐步下降。值得注意的是，尽管各个节点的流量波动幅度有所不同，但整体趋势高度相似，显示出交通流量的日常周期性变化。这种规律性的高峰模式反映了城市交通在工作日通勤时段的典型特征。




图 2-4 日周期依赖

周周期模式通常表现为周末和工作日的交通模式差异，如图 2-5 所示，周一至周五的交通流量较高，尤其是在早高峰和晚高峰之间的时段。与工作日流量相比，周末的交通流量通常更为平稳，且流量相对较低。




图 2-5 周周期依赖

(3) 不确定性：交通数据的不确定性主要体现在其受多种随机性因素影响，导致预测结果存在波动和偏差。首先，突发事件会打破交通的正常规律，引发突变性变化。其次，人类行为本身具有高度随机性，不同驾驶者的反应和决策差异也会增加数据的不可预测性。此外，传感器故障、数据缺失或误差也可能引入噪声，进一步加剧不确定性。

(4) 非线性：交通数据随着时间和空间变化时，不遵循简单的线性关系，而呈现出复杂、不可预测的变化模式。外部干扰和路网内部的耦合传播效应进一步加剧了数据的非线性波动，即微小的变化也可能导致交通状态的巨大变化。

2.2 时空数据建模方法

针对交通流量的时空相关性，近年来提出了多种建模方法，结合时间序列建模与空间特征提取技术，能够更全面地捕捉交通数据的动态变化特性。接下来将分别针对时间和空间相关性建模的经典算法进行详细介绍。

2.2.1 时间相关性建模方法

时序建模是交通流量预测的重要组成部分，其核心在于捕捉时间维度上数据的动态变化模式。由于交通流量数据具有时空相关性、周期性、不确定性和非线性等特点，合适的时序建模方法可以有效提升预测精度。近年来，基于深度学习的时序建模方法，如时间卷积网络（Temporal Convolutional Network, TCN）^[52]和时间注意力网络（Temporal Attention Network, TAN）^[53]，在交通流量预测中取得了显著成效。

(1) 时间卷积网络

时间卷积网络是一种基于卷积神经网络的时序建模方法，它通过因果卷积和空洞卷积来捕捉时间依赖关系，同时避免了循环神经网络在长序列建模时存在的梯度消失和计算效率低下等问题。




图 2-6 标准一维卷积（左）和因果卷积（右）的差异

TCN 的核心特点是采用一维卷积结构进行时间序列建模，与标准一维卷积不同的是，因果卷积保证了时间顺序，即当前时刻的输出仅依赖于过去时刻的信息，而不会受到未来信息的影响，如图 2-6 所示，使得 TCN 符合因果性约束。其数学定义如式（2-4）所示。

$$h_t = f\left(\sum_{i=0}^{k-1} W_i x_{t-i} + b\right) \quad (2-4)$$

其中， h_t 是时间步 t 处的隐藏层输出， x_{t-i} 是输入序列中过去 i 个时间步的数据， W_i 是卷积核权重， b 是偏置项， k 是卷积核大小， $f(\cdot)$ 是非线性激活函数。




图 2-7 空洞卷积

此外，为了扩展感受野，TCN 采用了空洞卷积，即在卷积计算时引入间隔，使得感受野随着卷积层数的增加呈指数级扩展，从而能够捕捉远距离的时间依赖关系。其计算公式如式（2-5）所示。

$$h_t = f\left(\sum_{i=0}^{k-1} W_i x_{t-i \cdot d} + b\right) \quad (2-5)$$

其中， d 作为膨胀率（dilation factor），决定了输入数据点的间隔，当膨胀率 d 指数级增长（ $d = 1, 2, 4, 8 \dots$ ），TCN 可以在较少层数下获得大感受野，从而有效建模长时间依赖关系，而不会像 RNN 那样需要长时间循环计算，空洞卷积示意图如图 2-7 所示。

为了缓解深层网络的梯度消失问题，TCN 采用残差连接（Residual Connection），相关公式如式（2-6）所示。

$$h_t^{l+1} = f\left(W^{(l)} * h_t^{(l)} + b^{(l)}\right) + h_t^{(l)} \quad (2-6)$$

其中, $h_l^{(i)}$ 表示第 l 层的输出, 在 TCN 结构中, 通常使用残差连接和归一化(Normalization)策略来提高深层网络的训练稳定性。具体来说, 残差连接使得梯度可以更容易地传递到浅层网络, 缓解梯度消失问题, 而归一化可以稳定训练, 提高模型的泛化能力。综上, TCN 由于其能够捕捉长期依赖性和短期变化的能力, 在交通流量预测中表现出色, 具有广泛的应用前景。

(2) 时间注意力网络

时间注意力网络 (TAN) 是一种基于自注意力机制 (Self-Attention) [54] 的时序建模方法, 能够动态分配不同时间步的权重, 以捕捉时间依赖关系和全局时序模式。相比于传统的递归神经网络和卷积神经网络, TAN 模型通过计算时间序列内部的注意力权重矩阵, 能够直接关注关键时间步, 从而提高对时间依赖关系的建模能力, 特别适用于长期时间预测任务。注意力机制如图 2-8 所示。




图 2-8 注意力机制

在 TAN 模型中, 输入的时间序列首先被投影到查询 (Query)、键 (Key) 和值 (Value) 空间, 相关过程如式 (2-7) 所示。

$$Q = XW_Q, K = XW_K, V = XW_V \quad (2-7)$$

然后, 通过点积注意力计算不同时间步之间的相关性, 计算过程如式 (2-8) 所示。

$$A = \text{soft max}\left(\frac{QK^T}{\sqrt{d}}\right) \quad (2-8)$$

其中, d 是 Key 的维度, A 表示不同时间步之间的注意力分布, 能够反映时间步之间的相对重要性。最终, 注意力矩阵绝对值 V 进行加权求和, 得到加权后的时间序列表示如式 (2-9) 所示。

$$H = AV \quad (2-9)$$

这种计算方式允许 TAN 模型直接建模时间步之间的全局依赖关系, 避免了 RNN 结构中的梯度消失问题。为了增强模型的表示能力, TAN 模型采用多头注意力 (Multi-Head Attention, MHA) 机制, 即将输入投影到多个子空间并并行计算多个注意力矩阵, 其计算方式如式 (2-10) 所示。

$$MHA(X) = \text{Concat}(H_1, H_2, \dots, H_h)W_O \quad (2-10)$$

其中, h 是注意力头的数量, W_O 是最终的线性变换矩阵。通过多头注意力机制, TAN 可

以从不同的表示子空间学习多样化的时间依赖模式,从而提高模型的泛化能力和稳定性。此外,为了优化深层网络的训练,TAN 模型采用残差连接和层归一化来增强训练的稳定性,其中残差连接可以缓解梯度消失问题,使得模型更容易优化,而层归一化有助于提升收敛速度,使得模型能够更稳定地学习依赖关系。

同时,TAN 模型还包含一个前馈神经网络(Feed-Forward Network, FFN),用于对每个时间步的表示进行非线性变换,以提高模型的表达能力,其计算方式如式(2-11)所示。

$$F(H') = \text{ReLu}(H'W_1 + b_1)W_2 + b_2 \quad (2-11)$$

其中, W_1, W_2 是可训练的权重, b_1, b_2 是偏置项,该前馈网络能够增强模型的非线性表示能力,使得 TAN 能够适应更加复杂的时序模式。

在实际应用中,TAN 模型适用于需要建模长期依赖关系的时间序列任务,如交通预测、天气预测、金融时间序列分析等。相较于传统的时间序列建模方法,TAN 模型由于其全局注意力机制,能够更好地识别序列中的重要模式,提高预测的准确性,并且避免了递归网络在序列建模中出现的信息遗忘问题。因此,TAN 模型已成为时序建模领域的一种重要方法,并在多个应用场景中展现出了优越的性能。

2.2.2 空间相关性建模方法

在交通流量预测中,除了时间维度上的变化外,不同道路之间的空间关联性同样对流量变化起着关键作用。因此,建立能够捕捉复杂空间依赖关系的建模方法,对于提升预测精度至关重要。本节主要介绍经典的图神经网络,它能够有效建模交通网络中的空间依赖关系,从而更准确地刻画不同道路之间的相互影响。

图神经网络(Graph Neural Network, GNN)^[25]是一种专门用于处理图结构数据的深度学习方法,能够有效地建模节点及其连接关系。与传统的神经网络不同,GNN 通过迭代聚合节点邻域信息,使得每个节点的表示不仅包含自身特征,还能够捕捉局部和全局的拓扑信息。在 GNN 结构中,节点的特征通过多层传播更新,通常采用消息传递机制(Message Passing),其核心计算方式如式(2-12)所示。

$$h_v^{l+1} = \sigma(\sum_{u \in \mathcal{N}(v)} f(h_u^{(l)}, h_v^{(l)}, e_{uv})) \quad (2-12)$$

其中, $h_v^{(l)}$ 表示节点 v 在第 l 层的特征表示, $\mathcal{N}(v)$ 为其邻居节点的集合, e_{uv} 表示边的特征, $f(\cdot)$ 是邻居特征聚合函数, $\sigma(\cdot)$ 是非线性激活函数。

GNN 的核心思想在于每一层通过聚合邻居信息逐步增强节点表示,使得模型能够有效学习复杂的图结构模式。图神经网络消息传递过程如图 2-9 所示。在交通预测任务中,路网可以表示为一个图结构,其中道路交叉口或检测点作为图的节点,路段或车流联系作为边。GNN 能够学习道路之间的时空依赖关系,提高预测的准确性。在交通流量预测中,GNN 可以通过聚合邻居道路的历史流量信息,学习整个交通网络的流量变化模式,

为未来时间段提供更精准的预测结果。通过多层特征传播，GNN 逐步捕获从局部到全局的交通动态特征，使预测结果更具鲁棒性。




图 2-9 消息传递过程

2.3 扩散模型基础理论

去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）^[36]是一类基于概率论的生成模型，近年来在图像生成和其他生成任务中取得了显著的进展。DDPM 的主要思想来源于分数匹配^[55]和去噪自编码器（Denoising Autoencoder）^[56]的结合，旨在通过逐步添加噪声并学习如何去除这些噪声来生成数据，具有高质量生成、训练稳定等优势。DDPM 是一种潜变量模型， x_n 表示潜变量的序列， $x_1, \dots, x_{t-1}, x_t, \dots, x_T$ 是一个逐步向 $x_0 \sim q(x_0)$ 添加高斯噪声的过程，其中， x_0 是原始数据， x_T 是纯噪声数据。DDPM 的目标是通过学习分布 $p_\theta(x_0) = \int p_\theta(x_{0:T}) dx_{1:T}$ 来逼近目标分布 $q(x_0)$ 。DDPM 的核心思想是通过两个过程，前向过程（forward process）和反向过程（reverse process）来生成数据。在前向过程中，DDPM 逐步向真实数据添加噪声，最终将其转化为纯噪声；在反向过程中，DDPM 从纯噪声样本开始，逐步去除噪声，恢复为原始数据。这一框架可以理解为通过逐步变换数据，最终学会如何从噪声中恢复出数据。DDPM 具体过程如图 2-10^[36]所示。




图 2-10 DDPM 示意图

2.3.1 前向过程

前向过程是一个逐步向原始数据 x_0 添加噪声的过程，遵循马尔科夫链的形式，并且不涉及可学习参数。其概率表示如式（2-13）所示。

$$q(x_{1:T}:x_0) = \prod_{t=1}^T q(x_t|x_{t-1}) \quad (2-13)$$

$q(x_{1:T}:x_0)$ 是指给定原始数据 x_0 的条件下，生成噪声数据序列 x_1 到 x_T 的整体分布。这表示

从 x_0 开始, 逐步添加噪声以生成 x_1 到 x_T 的序列。具体而言, $q(x_{1:T}|x_0)$ 是一个高斯分布, 表示方法如式(2-14)所示。

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I) \quad (2-14)$$

其中, $\alpha_t = 1 - \beta_t$, $\beta_t \in (0,1)$ 是控制噪声水平的方差超参数。与逐步对 x_t 采样不同, 递归公式可以直接获得任意步 t 的条件分布, 递归公式如式(2-15)所示。

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I) \quad (2-15)$$

其中, $\bar{\alpha}_t = \prod_{m=1}^t \alpha_m$ 。该公式表明, 任意时刻 t 的数据都可以直接通过在 x_0 的基础上添加某种程度的高斯噪声得到, 并且可以将其重新参数化, 具体参数化过程如式(2-16)所示。

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon \quad (2-16)$$

其中, $\epsilon \in \mathcal{N}(0, I)$ 是从标准高斯分布中采样的噪声, 这种重参数化形式为后续反向过程中的去噪过程提供了便利, 使得模型能够学习从任意噪声状态 x_t 恢复到原始数据 x_0 的映射关系。随着噪声水平的增加, 数据分布逐渐趋于各向同性的高斯分布, 最终在 $t = T$ 时完全退化为标准高斯噪声分布, 表达式如式(2-17)所示。

$$q(x_T) \approx \mathcal{N}(0, I) \quad (2-17)$$

这种将复杂数据分布逐步转换为高斯分布的过程, 奠定了反向过程的基础。

2.3.2 反向过程

反向过程是从纯高斯噪声 x_T 开始逐步去噪以恢复原始数据 x_0 的过程, 同样遵循马尔科夫链, 相关过程如式(2-18)和(2-19)所示。

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t) \quad (2-18)$$

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \sigma_\theta(x_t, t)I) \quad (2-19)$$

其中, θ 表示所有可学习参数, $p_\theta(x_{0:T})$ 表示从 x_T 到 x_0 的完整状态序列的联合概率分布, 在参数 θ 的条件下, 它表示从纯高斯噪声开始, 通过逐步去噪恢复原始数据。这个过程可以分解为初始分布 $p(x_T)$ 和逆向转移概率 $p_\theta(x_{t-1}|x_t)$ 的乘积。

而逆向转移概率 $p_\theta(x_{t-1}|x_t)$ 用于描述从状态 x_t 逆向回退到前一状态 x_{t-1} 的概率, 它被建模为一个高斯分布, 其中均值和方差由神经网络 $\mu_\theta(x_t, t)$ 和 $\sigma_\theta(x_t, t)$ 参数化。具体来说, 逆向转移概率的参数化的表示如式(2-20)和(2-21)所示。

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) \quad (2-20)$$

$$\sigma_\theta(x_t, t) = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \quad (2-21)$$

其中, $\mu_\theta(x_t, t)$ 是逆向转移分布 $p_\theta(x_{t-1}|x_t)$ 的均值, 表示在给定 x_t 和时间步 t 的条件下, 期望 x_{t-1} 的值。它通过当前的噪声样本 x_t 、噪声调度参数 β_t 和模型的噪声估计值 $\epsilon_\theta(x_t, t)$

计算得到。而 $\sigma_\theta(x_t, t)$ 是逆向转移分布的方差，表示从 x_t 恢复 x_{t-1} 时的不确定性，其大小取决于噪声调度参数 β_t 和累计噪声减少量 $\bar{\alpha}_t$ ，它调节了反向过程中的不确定性水平。

这种参数化保证了在反向过程的每一步都能够有效减少噪声，使得数据逐步向真实分布收敛。随着反向过程的进行，模型逐步去除噪声，最终将纯高斯噪声 x_T 转换为一个接近原始数据分布的样本。通过最小化基于 KL 散度的变分下界（ELBO），模型可以学习到最优的去噪路径，从而实现对数据的高效生成和重构。

2.3.3 去噪网络

去噪网络（Denoising Network）是扩散模型的核心组件，承担了在反向过程中估计噪声 $\epsilon_\theta(x_t, t)$ 的任务。去噪网络的目标是学习如何在扩散模型的反向过程中逐步去除噪声，从纯噪声样本恢复出原始数据。去噪网络 ϵ_θ 的训练目标是 minimize 负对数证据下界（Evidence Lower Bound, ELBO），从而提高生成数据的质量。ELBO 是基于变分推断（Variational Inference）的优化目标，通过最小化真实逆向分布 $q(x_{t-1}|x_t)$ 与学习到的分布 $p_\theta(x_{t-1}|x_t)$ 之间的 Kullback-Leibler (KL) 散度来进行训练，其数学形式如式（2-22）所示。

$$\mathcal{L}(\theta) = \mathbb{E}_{q(x_{0:T})} \left[-\log p(x_T) - \sum_{t=1}^T \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t)} \right] \quad (2-22)$$

该目标函数包括每一步噪声数据的对数似然以及逆向和前向概率的比值，确保模型在反向过程中尽可能恢复原始数据。为了简化训练过程，DDPM 对逆向分布进行参数化，并进一步将训练目标优化为一个噪声预测损失。训练过程可以进一步优化，如式（2-23）所示。

$$\mathcal{L}(\theta) = \mathbb{E}_{x_0, \epsilon, t} \|\epsilon - \epsilon_\theta(x_t, x)\|_2^2 \quad (2-23)$$

通过最小化该损失函数，去噪网络学会如何准确预测在不同时间步 t 下的噪声，使其能够在反向过程中精确去除噪声，从而生成与原始数据分布一致的高质量样本。精确的噪声估计和高效的反向去噪能力是扩散模型生成高质量数据的关键所在。

2.4 总结

本章围绕交通预测任务所依赖的基础理论与关键技术展开了系统阐述，旨在为后续模型的构建与方法设计提供坚实的理论支撑。这些理论不仅奠定了研究工作的基础框架，也为理解交通数据的内在结构特征、明确建模重点与优化方向提供了重要指导，有助于提升模型的针对性与有效性，从而更精准地应对复杂多变的交通预测场景。

首先，从交通流理论出发，介绍了交通数据的基本概念以及交通数据在时间与空间维度上的显著特性，如时空相关性、周期性、不确定性与非线性，这些特性直接影响着模型的设计与建模策略。理解这些特性有助于从根本上把握交通数据的动态变化规律，

为后续模型在捕捉时空依赖性和处理不确定性方面提供理论基础，确保模型能够贴合实际交通环境，提升预测的实用性与可靠性。

其次，围绕时空数据的建模方法，详细解析了时间相关性建模中的两种主流方法：时间卷积网络与时间注意力网络，并分别探讨了它们在提取时间序列特征、捕捉长期依赖方面的优势与适用场景；在空间建模部分，则重点介绍了基于图结构的空间建模方法，尤其是图卷积网络在交通网络建模中的广泛应用与强大能力，为捕捉交通路网的复杂空间关系提供了有力工具。

最后，结合本文的不确定性建模需求，介绍了扩散模型的基本原理与生成机制，分析了其在建模数据分布、处理预测不确定性方面的潜力，并为后续章节中扩散模型在交通预测中的应用奠定理论基础。

第三章 基于多分量时序图神经网络的交通预测方法

3.1 引言

交通数据中蕴含的复杂组成成分共同构成了交通数据高度非线性、强时空依赖的特性。但是，传统方法通常将交通数据视为整体进行统一建模，忽略了不同组成成分在动态特性上的差异性，难以针对性地提取有效特征，进而影响模型的预测准确性与泛化能力。因此，近年来越来越多的研究开始尝试对交通数据进行成分解耦，即将原始流量序列拆解为具有不同动态属性的子序列，并针对各子项设计专门的子模型进行建模。这种方法不仅能够提升模型对不同模式的感知能力，还能有效降低建模的复杂度与噪声干扰，提高预测的稳定性与准确性。

受交通数据特性的启发，本章提出了一个基于多分量时序图神经网络（Multivariate Temporal Graph Neural Network, MTGNN）的交通预测模型。如图 3-1 所示，交通数据通常包含长期趋势、季节性变化、周期波动和不规则波动，本章重点关注交通数据所包含的趋势项与季节项，并针对不同特征采用专门的时空建模方法进行处理。相关研究中^[57]表明对于具有强周期性的交通数据，频域注意力模型比时域注意力更具有样本效率。因此，对于季节项，MTGNN 模型采用傅里叶注意力（Fourier Attention）^[58]进行建模；对于趋势项，则采用时间卷积网络（TCN），这是由于在处理趋势性较强的数据时，TCN 表现出更强的捕捉长期依赖性的能力。




图 3-1 交通数据分解示意图

此外,考虑到交通路网通常表示为稀疏图结构,使用全局性的图注意力网络在建模空间依赖关系时会显著增加计算复杂度。为此,本章对图注意力机制进行了优化设计,在保证建模精度的同时降低计算成本,提高整体建模效率。

在章节安排中,本章的第二节对交通预测核心概念与相关定义进行了明确阐述。第三节详细介绍了模型的整体框架和各个关键模块,剖析了其设计理念与实现方式。第四节介绍了实验设置和数据集情况以及对比实验。其中,实验一为本章模型与经典模型的精度对比实验,实验二为本章模型的参数学习实验,实验三为本章模型的消融实验。最后,第五节对本章内容进行了总结,强调了模型的优势,为后续研究提供参考。

3.2 交通预测问题定义

由于交通数据具有复杂的时空相关性,精确捕捉不同时间步和不同位置之间的动态变化成为构建高性能交通预测模型的关键。为此,本节首先引入必要的数学符号,并对相关概念进行正式定义,以为后续模型构建和实验分析奠定基础。

定义 1: (交通网络) 给定一个现实世界的交通路网图,时间序列作为图信号。在交通预测中,本章将交通道路网络表述为预测交通的有向图 $G\{N, E, A\}$, 其中 N 是部署在交通路网图中的传感器节点, E 是相邻传感器之间边的集合, $A \in \mathbb{R}^{N \times N}$ 是图的邻接矩阵。对于每个传感器节点 i , 将其在一个时间步长 T 上的信号定义为 $X_i = \{x_i^1, x_i^2, \dots, x_i^T\} \in \mathbb{R}^{T \times F}$, F 是特征维数。 $X = \{X_1^T, X_2^T, \dots, X_N^T\} \in \mathbb{R}^{N \times T \times F}$ 表示时间步长 T 时所有传感器节点的交通数据。

定义 2: (交通预测) 交通预测问题旨在通过已知的 N 个传感器节点的历史 T 个时间片的交通数据学习一个函数来预测交通道路上未来 T' 个时间片的交通情况, 相关公式如式 (3-1) 所示。

$$X_{1:T} \rightarrow Y_{T+1:T+T'} \quad (3-1)$$

3.3 多分量时序图神经网络模型

本节提出了一种名为多分量时序图神经网络的新模型, 简称为 MTGNN, 旨在提高交通预测的准确性。MTGNN 模型通过对交通流数据进行趋势与季节性的分解处理, 分别针对不同成分采用差异化的建模策略, 以更好地捕捉数据的复杂时空特性并提升预测效果。针对不同特性的成分, 模型采用不同的时空建模策略来捕捉交通流量的动态特征, 从而实现更精准的预测。

3.3.1 模型框架

图 3-2 为 MTGNN 的模型结构图, 该模型由数据分解模块、时空建模模块以及输出模块三部分组成。在数据分解阶段, MTGNN 模型通过季节趋势分解 (Seasonal-Trend

Decomposition) 将输入的交通数据拆分为趋势项和季节项, 并分别输入至后续的建模分支中。

对于季节项, 模型引入傅里叶注意力机制和改进后的图注意力网络, 以更有效地捕捉长期演化规律与空间依赖关系; 而对于趋势项, 模型采用时间卷积网络和改进后的图注意力进行建模, 以建模其周期性变化模式。最后, 在输出模块中, 模型将趋势和季节两个分支的建模结果进行融合, 生成最终的预测结果。本章后续小节将对模型各模块的设计与实现细节进行详细阐述。




图 3-2 MTGNN 模型示意图

3.3.2 数据分解模块

本节采用了多尺度平均滤波器 (multi-scale average filters) 来提取不同时间尺度上的趋势和季节模式, 并通过自适应加权机制将这些不同尺度的趋势模式组合为最终的趋势和季节成分。与传统的固定窗口平均不同, 这种多尺度滤波方法能够更灵活地捕捉数据中的长短期趋势变化, 从而提高趋势分解的准确性。

设输入数据为 $X \in R^{L \times d}$, 其中 L 为时间序列的长度, d 为特征维度。通过多个不同大小的滑动平均滤波器对数据进行平滑操作, 可以提取不同时间尺度上的趋势成分。最终的趋势成分 $X_t \in R^{L \times d}$ 由自适应加权组合得到, 而季节性成分 $X_s \in R^{L \times d}$ 则是通过从原始数据中减去趋势部分获得。其计算过程如式 (3-2) 和 (3-3) 所示。

$$X_t = \sigma(w(X)) * f(X) \quad (3-2)$$

$$X_s = X - X_t \quad (3-3)$$

其中, $\sigma(\cdot)$ 表示 softmax 操作, 确保不同尺度趋势的权重之和为 1, $w(X)$ 代表数据自适应

权重，通过学习机制根据数据特性为不同尺度趋势分配权重， $f(X)$ 表示不同尺度的平均滤波器，用于提取不同时间尺度的趋势特征， $*$ 表示加权组合操作。

这种趋势与季节性成分的解耦策略不仅有助于提高数据建模的准确性，还可以减少不同频率特征之间的相互干扰，使模型在建模时空依赖关系时更加高效。此外，多尺度趋势提取结合自适应加权机制，使得模型能够根据数据的不同特性动态调整趋势成分的权重，从而提升复杂交通数据的建模能力。

3.3.3 时空建模模块

解耦后的趋势成分和季节性成分分别进入不同的建模模块进行建模。由于本模型中捕捉趋势部分时间相关性的 TCN 已在第二章中详细介绍，因此本节将重点阐述傅里叶注意力机制和用于捕捉空间相关性的模型图注意力网络以及对图注意力网络的改进。

(1) 傅里叶注意力模型

该模型旨在提升模型对时间序列中周期性模式的建模能力，尤其适用于季节性特征明显的的数据。该方法将传统注意力机制从时间域迁移至频率域进行建模，通过对输入序列进行快速傅里叶变换（FFT）^[59]，捕捉其主要频率成分。由于傅里叶变换能够有效提取周期性变化的模式，使得模型在频域中更具样本效率与泛化能力。具体而言，傅里叶注意力网络首先对输入序列进行频域转换，分别生成频域下的查询（Q）、键（K）和值（V）。随后在频域中完成注意力计算，并通过反向快速傅里叶变换将结果映射回时间域，傅里叶注意力模型结构图如图 3-3 所示。




图 3-3 傅里叶注意力模型

相比传统注意力机制，傅里叶注意力能更聚焦于主导频率，有助于准确提取季节性信息，同时借助 FFT 降低了计算复杂度，从 $O(N^2)$ 优化为 $O(N \log N)$ ，在效率和性能上都具有明显优势，其计算公式如式（3-4）、（3-5）、（3-6）和（3-7）所示。

$$Q_f = FFT(X_s W_q) \quad (3-4)$$

$$K_f = FFT(X_s W_k) \quad (3-5)$$

$$V_f = FFT(X_s W_v) \quad (3-6)$$

$$\hat{X}_s = iFFT(\text{softmax}(Q_f K_f^T) V_f) \quad (3-7)$$

(2) 图注意力网络

在交通预测任务中，空间相关性是建模的关键因素。不同区域的交通流量往往具有强烈的空间依赖关系，相邻路段之间的流量变化具有显著的关联性。全局 GAT^[60]通过在图结构中建模各个路段之间的动态依赖关系，能够有效捕捉复杂的空间交互特性，从而提升模型的预测精度。

全局 GAT 通过引入自注意力机制来动态调整图中节点邻居的重要性，从而提升对图结构数据的建模能力。与传统的图卷积网络不同，全局 GAT 在聚合邻居节点信息时，不再是直接对邻居节点的特征进行均值或加权求和，而是通过自注意力机制根据邻居节点与当前节点的重要性进行加权求和，这使得全局 GAT 能够在复杂的图结构中捕获更加精细的空间依赖关系。

设输入的图信号为 $X \in R^{N \times d}$ ，其中 N 表示节点数量， d 为节点维度。全局 GAT 通过计算节点 i 和其邻居节点 j 之间的注意力权重来对邻居特征进行加权聚合，其计算过程如式 (3-8)、(3-9) 和 (3-10) 所示。

$$e_{ij} = \text{Leaky Re Lu}(a^T [Wx_i || Wx_j]) \quad (3-8)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in N(i)} \exp(e_{ik})} \quad (3-9)$$

$$h_i' = \sigma(\sum_{j \in N(i)} \alpha_{ij} Wx_j) \quad (3-10)$$

其中， $W \in R^{d \times d'}$ 为可学习的特征变换矩阵，将原始特征映射到新的特征空间， a 为注意力机制的参数向量， e_{ij} 表示节点 i 和邻居节点 j 之间的注意力系数， α_{ij} 是节点 i 对邻居节点 j 的注意力权重，通过 *softmax* 归一化得到， $\sigma(\cdot)$ 为激活函数，通常使用 *ReLU* 或者 *ELU*， h_i' 为节点 i 经过全局 GAT 更新后的特征表示。

(3) 改进后的图注意力网络

全局 GAT 计算复杂度为 $O(N^2)$ ，当传感器数量 N 较大时，计算成本和内存占用都会显著增加。降低复杂度的直接方法是仅对邻居节点进行信息聚合，这将退化为传统 GAT，并导致全局信息丢失。因此，本节引入了一种查询采样策略 (*query sampling strategy*)^[61]，在降低计算复杂度的同时，保持全局感受野，从而有效捕获区域级信息。

查询采样策略通过选择少量关键传感器作为稀疏查询 (*sparse queries*)，吸收来自所有传感器的信息，并利用相关性将未采样的传感器结果从最相似的传感器复制。这一策略基于区域或社区内传感器通常具有相似功能和流量特性的观察，这种特性在层次化交通系统中尤为突出。在计算过程中，首先进行初步信息聚合，通过 GAT 在传感器时间序列之间进行信息传播，计算公式如式 (3-11) 和 (3-12) 所示。

$$m_n^t = \sum_{i \in N_n} \gamma_{n,i}^t (W_V Mx_i^t) \quad (3-11)$$

$$\gamma_{n,i}^t = \frac{\exp((W_Q Mx_n^t)^T (W_K Mx_i^t))}{\sum_{k \in N_n} \exp((W_Q Mx_n^t)^T (W_K Mx_k^t))} \quad (3-12)$$

其中, m_n^t 表示传感器 n 在时间步 t 的聚合信息, N_n 表示传感器 n 的邻居集合, $W_Q M$ 、 $W_K M$ 、 $W_V M \in R^{d \times d}$ 为可训练参数矩阵, $\gamma_{n,i}^t$ 表示注意力权重, 衡量邻居传感器 i 对传感器 n 的影响程度。

接下来, 本节使用 Top-k 池化 (topk-pooling) 策略从 N 个传感器中选出 S 个活跃传感器作为稀疏查询, 这些传感器可以代表区域的特征, 如式 (3-13) 和 (3-14) 所示。

$$S = \lfloor e \log N \rfloor \quad (3-13)$$

$$idx_t = \text{rank}\left(\frac{M_t P}{\|P\|}, S\right) \quad (3-14)$$

其中, e 作为一个常数采样因子, S 控制活跃分子传感器数量, $M_t \in R^{N \times d}$ 为时间步 t 的传感器得分矩阵, $P \in R^{d \times 1}$ 为可训练的投影向量, 将 M_t 投影到 1 维, 得到每个传感器的重要性得分, $\text{rank}(\cdot, S)$ 返回前 S 个最大值的索引, $idx_t \in R^S$ 为被选中的传感器的索引。对于选中的关键传感器, 在子图上进行稀疏 GAT 计算公式如式 (3-15) 所示。

$$x_{gat,n}^t = \sum_{i=1}^N \beta_{n,i}^t (W_V^S x_i^t) \quad (3-15)$$

其中, $n \in idx_t$, $W_V^S \in R^{d \times d}$ 为稀疏 GAT 的特征变换矩阵, $\beta_{n,i}^t$ 为活跃传感器 n 从其他传感器 i 处获取信息的注意力权重。

对于未被采样的传感器, 本节直接从与其相关性最高的活跃传感器复制结果, 具体过程如式 (3-16) 和 (3-17) 所示。

$$x_{gat,n}^t = x_{gat,c}^t \quad (3-16)$$

$$c = \text{rank}(\beta_{:,n}^t, 1) \quad (3-17)$$

其中, c 表示与未采样传感器 n 相关性最高的传感器索引, 该索引通过权重 $\beta_{:,n}^t$ 中的最大值获取。引入查询采样策略后, 全局 GAT 的计算复杂度从 $O(N^2)$ 降至 $O(N \log N)$, 显著降低了计算和内存消耗。由于仅对关键传感器进行完整的 GAT 计算内存占用量也由 $O(N^2)$ 减少到 $O(N \log N)$, 实现了资源的高效利用。改进后的 GAT 网络如图 3-4 所示。经过低复杂度 GAT 处理后, 传感器间的空间特征得到有效建模, 并与时间特征模块结合, 为交通预测提供更全面的时空表示。




图 3-4 改进后 GAT 网络结构示意图

3.3.4 数据融合与预测

为了获得最终的预测结果，模型对季节预测和趋势预测的输出进行求和，实现数据融合，具体过程如式（3-18）所示。

$$X_{final} = H_t + H_s \quad (3-18)$$

融合后的预测结果通过全连接层映射到目标时间步进行最终预测，相关过程如式（3-19）所示。

$$\hat{Y} = W_o X_{final} + b_o \quad (3-19)$$

其中， $W_o \in R^{d \times 1}$ 为映射矩阵， b_o 为偏置项。通过求和融合趋势与季节特征，有效平衡了短期与长期特性，从而提升模型的预测精度。

3.4 实验设计与结果分析

本节主要介绍实验的具体设置与分析，以验证所提出模型的有效性。首先，本节描述实验环境、使用的数据集和参数配置，然后介绍评价指标，并通过实验结果分析模型的预测性能。

3.4.1 实验相关设置

（1）实验环境介绍

本研究基于 Python 和 PyTorch 进行实现，所有实验均在 Nvidia GeForce RTX 3060 上进行。模型训练时使用 CUDA 11.1 进行加速，并结合 cuDNN 8.5.0 以提升计算效率。

（2）实验数据集简介

本章的实验数据集是在加州交通运输机构绩效测量系统收集的四个真实公开数据集，数据集地图与节点分布示意图如图 3-5 所示。这些数据集包括 PeMS03、PeMS04、PeMS07 和 PeMS08，均以 5 分钟为间隔进行数据采样，且被广泛应用于交通流量预测任务。具体而言：

PeMS03：该数据集由 PeMS 在洛杉矶地区收集，包含 358 个传感器，时间跨度为 2018 年 9 月 1 日至 2018 年 11 月 30 日，用于捕获城市区域复杂的交通模式。

PeMS04：该数据集来自旧金山湾区，由 307 个传感器记录，数据覆盖时间为 2018 年 1 月 1 日至 2018 年 2 月 28 日，反映了该地区的交通流量变化趋势。

PeMS07：该数据集由 PeMS 在圣地亚哥地区收集，包含 228 个传感器，时间跨度为 2017 年 5 月 1 日至 2017 年 8 月 31 日，主要用于捕捉郊区的交通动态变化。

PeMS08：该数据集来源于圣贝纳迪诺地区，包含 170 个传感器，时间跨度为 2016 年 7 月 1 日至 2016 年 8 月 31 日，记录了郊区交通流量的时空特征。




图 3-5 数据集地图与节点分布示意图

(3) 实验参数设置

本章的实验使用了前 12 个时间步长的观测流量数据来预测未来 12 个时间步长的流量变化。数据集按照时间顺序划分为训练集（60%）、验证集（20%）和测试集（20%），时间粒度为 5 分钟，以确保时间序列的连续性和预测的准确性。

模型的训练过程中采用 Adam 优化器，并设置初始学习率为 0.001，批量大小为 32，训练轮数为 200。为了应对训练过程中可能出现的过拟合现象，实验设计了学习率衰减策略，当验证集损失在连续 20 轮内未改善时，学习率衰减至原来的 1/10。此外，实验还引入了早停策略（Early Stopping），通过监控验证集的 MAE 和 RMSE 值来避免过拟合，若验证集损失在连续 20 轮内未出现提升，训练将提前终止。

在超参数配置方面，模型采用了 8 个注意力头，特征维度为 16，最终特征维度为 128。因果卷积中的卷积核大小设置为 2，能够有效捕捉时序数据中的因果关系。为确保模型在不同数据集上的鲁棒性和最佳性能，实验通过网格搜索对超参数进行了调优。

(4) 评价指标

为了评估模型的预测性能，并比较预测值 $\hat{y}$ 与真实值 y 之间的差异，实验采用了 MAE、RMSE 和 MAPE 作为评价指标。这些指标能够全面反映模型的误差特征和表达能力，从多个角度衡量预测效果，同时帮助分析模型在不同场景下的适用性和稳定性。

MAE（Mean Absolute Error，平均绝对误差）用于衡量预测值与真实值之间的平均偏差，能够直观反映模型的整体预测精度。其数值越小，说明模型的预测误差越小，适用于衡量模型的全局准确性，表达式如式（3-20）所示。

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (3-20)$$

RMSE（Root Mean Squared Error，均方根误差）进一步考虑了误差的平方，使得较大的误差在计算中占据更大的权重，从而对预测中较大的偏差更加敏感。相比 MAE，RMSE 更能突出极端误差对模型稳定性的影响，有助于评估模型在面对异常数据时的鲁

棒性，表达式如式（3-21）所示。

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (3-21)$$

MAPE（Mean Absolute Percentage Error，平均绝对百分比误差）则通过将误差表示为预测值与真实值之差的相对比例，提供了一种衡量预测相对误差的方式。MAPE 不仅能反映误差的绝对大小，还能帮助衡量模型在不同数据规模和范围下的预测表现。由于其单位为百分比，MAPE 能够在跨不同任务或数据集时提供更为直观的误差度量，特别适用于比较具有不同量级的预测任务，表达式如式（3-22）所示。

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (3-22)$$

这三种评价指标的综合使用，能够多维度地评估模型在不同条件下的预测效果，尤其是在处理不同类型的误差时，能够有效避免单一指标的偏差。通过这些指标的对比，能够更全面地理解模型在不同情境下的表现，从而为模型的改进和优化提供有力支持。

3.4.2 实验一：MTGNN 模型与经典预测模型的精度对比实验

为综合对比 MTGNN 模型的预测精度，本文挑选了经典的预测模型进行对比实验，所选择的预测模型如下：

HA：历史平均法^[62]。通过对相同时间段的历史数据求平均来进行预测。实验中，按天、按周分别计算同一时刻历史数据的平均值作为预测结果。

ARIMA：整合移动平均自回归模型^[63]。实验中对交通流序列单独训练 ARIMA 模型，并使用 Akaike 信息准则选择最优的阶数组合。

SVR：基于支持向量机的回归方法^[64]。在实验中使用带 RBF 核的 SVR 并通过网格搜索优化超参数。

LSTM：长短时记忆模型^[18]。在实验中 LSTM 模型包含两层 LSTM 单元。

ASTGCN：ASTGCN 模型^[51]利用空间注意力机制与时间注意力机制动态建模交通流中的时空依赖关系，并结合图卷积与时间卷积进行联合学习。

PDFormer：PDFormer 模型^[65]基于时空自关注机制，解决了交通任务中复杂交通数据动态、长距离、时延的问题。

MTGNN：本文提出的基于多分量的时序图神经网络的交通预测。

在上述对比模型中，HA 和 ARIMA 模型为传统的时间序列模型，SVR 为传统的机器学习模型。在深度学习模型中，LSTM 仅考虑时间相关性，ASTGCN 和 STGODE 模型同时考虑空间和时间相关性。

表 3-1 展示了 4 个数据集下的 MTGNN 和对比模型的三个指标下的结果。从实验结果可以看出，MTGNN 在所有数据集上均取得了最佳性能，显著优于传统时间序列方法和其他深度学习模型，通过对比分析表中的数据，可以得到以下结论。

表 3-1 MTGNN 模型与对比模型的性能比较

Methods	PeMS03			PeMS04			PeMS07			PeMS08		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
			(%)			(%)			(%)			(%)
HA	31.58	52.39	33.78	38.03	59.24	27.88	45.12	65.64	24.51	34.86	59.24	27.88
ARIMA	35.41	47.59	33.78	33.73	48.8	24.18	38.17	59.27	19.46	31.09	44.32	22.73
SVR	21.79	35.11	21.72	28.70	44.76	18.90	33.55	51.33	15.36	24.44	37.17	25.23
LSTM	20.93	33.29	22.45	25.98	40.12	17.86	28.45	44.35	12.15	22.79	33.17	13.68
PDFormer	16.50	27.84	16.69	19.84	32.83	13.77	22.99	35.54	10.14	15.81	25.97	10.62
ASTGCN	17.33	28.34	17.11	21.97	34.12	16.34	22.78	36.56	10.45	17.94	28.05	11.56
MTGNN	16.13	28.12	16.36	18.87	32.41	13.38	21.26	34.35	9.16	14.75	25.65	9.85

尽管传统时间序列方法，如 HA 和 ARIMA 模型，在一些简单的预测任务中有所应用，但由于未能充分建模复杂的时空依赖性，这些方法在所有数据集上的预测误差均较大。例如，HA 模型无法捕捉交通流量的趋势和周期性变化，导致在动态变化较大的交通环境下预测性能较差。而 ARIMA 模型虽然能够对时间序列数据进行建模，但其主要假设线性关系，且无法应对交通数据中的非线性和复杂时空相关性，因此在处理复杂交通流量数据时，难以准确捕捉交通流量的动态变化。

基于机器学习的 SVR 模型相比传统统计方法有所提升，能够在一定程度上克服线性假设的限制，但其仍然存在难以有效建模长期依赖性的问题。SVR 主要依赖于局部数据特征进行预测，缺乏对交通流量长时间变化的准确把握。因此，SVR 模型的误差通常高于基于深度学习的方法，尤其在处理复杂的交通流量数据时，无法提供与深度学习模型相当的预测精度。

LSTM 模型作为一种能够建模时间依赖的神经网络，在部分数据集上表现较好，尤其在处理时间序列数据时能够有效捕捉到长期依赖性。然而，由于 LSTM 仅考虑时间依赖而忽略空间信息，在具有明显空间相关性的交通数据上，LSTM 的表现不及同时考虑时空依赖关系的方法。由于交通流量不仅是时间序列的变化，还受到地理位置和交通路网结构的影响，单独使用 LSTM 难以充分利用空间信息，因此整体性能仍然不如时空联合建模的方法。

相比之下，PDFormer 和 ASTGCN 模型作为时空图神经网络模型在所有数据集上均取得了明显优于传统方法的结果。其主要优势在于能够有效捕捉交通流数据中的复杂时空依赖性。PDFormer 和 ASTGCN 模型通过引入深层次的时空建模能力，能够同时考虑空间和时间的长距离相关性，从而更精确地捕捉交通流的动态变化。PDFormer 模型基于时空自关注机制，解决复杂交通数据动态、长距离、时延的问题，而 ASTGCN 模型则结合了时空注意力机制和图卷积网络，进一步提升了模型在捕捉周期性和长期依赖方面的能力。因此，基于图神经网络的时空建模方法，在复杂交通流数据的预测中展现出了更强的鲁棒性和准确性。

在四个真实数据集上, MTGNN 均取得了最低的 MAE, 这表明其对交通流量的点预测更加精准。相比于 PDFormer 模型, MTGNN 在绝对误差上平均减少了数辆车的偏差, 说明多分量解耦策略有效地减少了模型的系统偏差。MTGNN 在 RMSE 指标上同样表现最优。由于 RMSE 对大偏差具有平方惩罚效应, 其低值意味着 MTGNN 在遇到流量突增或突降等极端波动场景时, 能够显著降低预测偏离峰值的风险, 展现出更强的鲁棒性。




图 3-6 MTGNN 与 ASTGCN 模型预测结果中每个时间片下的指标比较

同时, 在所有数据集上 MTGNN 模型的 MAPE 最低, 这意味着其相对误差在高流量

和低流量时段都能保持极小水平，反映了模型在不同量级数据上的相对准确度，说明其在高峰拥堵与非高峰稀疏场景间都具有良好的适应性和泛化能力。

为了全面评估模型的预测性能，本节将模型与 ASTGCN 在每个时间片下的 MAE、RMSE 和 MAPE 进行了绘图分析，如图 3-6 所示，结果表明，MTGNN 模型在所有三个评价指标上均优于 ASTGCN，充分展示了其在时空特征建模表达的优势。

综合来看，实验结果验证了 MTGNN 在流量预测任务上的有效性，其优越性能主要得益于基于解耦的策略可以有效地帮助 MTGNN 定位每个节点在不同尺度下的动态变化，从而提升模型的可解释性，使得各成分的贡献更加清晰。此外，预测未来交通状况的趋势依赖和事件依赖也有异同，通过注意力机制整合辅助信息和主要信息，扩大了感知领域。考虑到这两个因素，MTGNN 在流量预测任务中始终优于其他方法，预测任务中均保持了较高的稳定性。

3.4.3 实验二：MTGNN 模型的超参数实验

为了深入理解模型的表现和优化潜力，本节在四个数据集上进行了超参数敏感性分析。首先，MTGNN 模型的性能随着时空相关性建模层数的增加而提高，并且当有 2 层时趋于稳定，如图 3-7 所示。这表明，适当增加网络的深度能够提高模型的表征能力，从而改善预测效果。然而，过多的层数可能会导致训练过程中的过拟合现象，因此在实际应用中，选择合适的层数对于模型性能至关重要。




图 3-7 MTGNN 模型中的层数分析

其次，实验结果显示，当特征个数为 128 时，模型能够达到最佳性能，如图 3-8 所示。显然，增加神经网络的规模能够增强模型的表征能力，但过多的特征可能会使模型在学习过程中受到噪声的影响，导致学习到的表征与实际需求不符，进而影响预测的准确性。这也表明，在特征选择时，需要综合考虑模型的复杂度与数据的噪声水平，找到合适的特征数量。本节通过对比不同超参数配置下的模型表现，进一步揭示了模型在不同超参数下的适应性和稳定性。这些分析结果为后续的模型优化和超参数调整提供了重要参考。




图 3-8 MTGNN 模型中的特征数分析

3.4.4 实验三：MTGNN 模型的消融实验

为了深入探究 MTGNN 模型中各关键模块对交通预测性能的影响，本节在多个真实交通数据集上进行了系统的消融实验。本次消融实验主要包括以下两个衍生模型：

(1) MTGNN-w/o-Seasonal-Trend Decomposition: 移除了季节趋势分解模块，直接对原始数据进行建模，不再进行时序解耦，以评估季节趋势解耦对于模型性能的影响。

(2) MTGNN-w/o-GAT: 移除了图注意力网络，仅保留时间卷积网络和时间注意力网络进行时序建模，从而评估空间特性建模在模型中的重要性。

上述衍生模型与 MTGNN 模型在交通预测的实验结果如表 3-2 所示。消融实验结果表明，去除季节趋势解耦模块后，模型在所有数据集上的预测性能均大幅下降，尤其是在具有显著周期性变化的数据集，如 PeMS03 和 PeMS04 上表现尤为明显。移除 GAT 后，模型的预测精度在所有数据集上均出现明显下降，表明捕捉邻近交通节点之间的空间相关性对于改善预测性能至关重要。

GAT 能够自适应地分配不同节点之间的信息权重，从而更精准地捕捉复杂交通网络中的空间依赖关系。实验结果显示，去除 GAT 后，模型对空间特性建模能力显著降低，导致所有数据集上的 MAE、RMSE 和 MAPE 发生大幅增加。尤其是在交通流变化较为复杂的 PeMS07 数据集上，性能下降最为明显，这进一步验证了 GAT 在空间特性捕获中的关键作用。

季节趋势解耦结合 GAT 的方式，使模型能够在不同时间尺度上捕获多层次的时空特性。实验结果表明，完整模型在不同数据集上均取得了最佳表现，说明该策略有助于应对不同数据集特性变化，提高模型的泛化能力。

消融实验结果表明，MTGNN 的关键模块，如季节趋势解耦和图注意力网络均对提升模型的预测精度起到了不可或缺的作用。完整模型在所有数据集上的表现优于去除任何一个模块的变体，充分证明了各模块协同作用在提升时空建模能力和准确性方面的重要性。消融实验进一步验证了各模块在不同数据集下的协同作用和互补优势，为未来的时空预测模型设计提供了有力的理论支撑。

表 3-2 消融实验结果对比

Datasets	Metric	w/o Trend-Seasonal	w/o GAT	MTGNN
PeMS03	MAE	17.62	19.56	16.13
	RMSE	30.74	32.32	28.12
	MAPE	17.73%	18.85%	16.36%
PeMS04	MAE	22.31	24.33	18.87
	RMSE	35.02	37.39	32.41
	MAPE	16.24%	16.06%	13.38%
PeMS07	MAE	23.41	26.56	21.26
	RMSE	35.27	40.43	34.35
	MAPE	11.21%	12.46%	9.16%
PeMS08	MAE	16.61	18.69	14.75
	RMSE	26.87	28.26	25.65
	MAPE	11.34%	12.19%	9.85%

3.5 总结

本章围绕交通流预测中确定性方法在复杂时空建模中的不足这一热点问题，提出了一种新颖的多分量时序图神经网络，简称为 MTGNN，旨在解决当前模型对不同时间周期特征建模能力有限、空间依赖理解不足等问题。该模型融合了时序分解策略与图神经网络架构，能够有效提取交通数据中的长期趋势与周期波动，提升对数据中不同部分动态的感知与建模能力。

首先，本章详细分析了交通预测任务中面临的两个主要挑战：（1）现有方法未能充分挖掘交通数据本身的周期性与多分量特性，缺乏针对性的数据建模机制；（2）现有空间建模方法结构复杂、计算成本高，难以在大规模交通网络中高效应用。针对上述问题，提出解决办法，从根本上提升了模型对交通流时空特征的捕捉能力。同时，为了更严谨地描述模型结构与任务目标，本文进一步对交通路网的结构进行了形式化定义，并在此基础上给出了交通预测任务的数学建模形式，为后续模型设计与实验评估奠定了理论基础。

其次，本章系统地介绍了 MTGNN 模型的整体架构及其核心模块的设计思路。该模型由多分量分解模块、时序建模模块和空间建模模块三部分组成。其中，多分量分解模块用于提取交通流数据中的长期趋势与周期性成分，实现数据的结构性解耦；时序建模模块采用差异化建模策略，分别捕捉不同分量的时序动态；空间建模模块则构建高效的图结构以建模交通路网中的空间依赖关系。在结构设计上，MTGNN 充分考虑了交通数据的周期性，能够同时兼顾长期演化趋势与短时周期波动，显著提升了模型的泛化能力与预测精度。该设计有效缓解了现有模型在复杂时空环境中预测性能不稳定的问题，为

交通流动态建模提供了新路径。

最后，本章介绍了实验设置与使用的数据集，并设计了三组实验以全面评估模型性能。实验一为模型与现有经典方法的对比实验，结果表明 MTGNN 在 MAE、RMSE 与 MAPE 三项指标上均优于其他对比模型，尤其在 PeMS07 和 PeMS08 数据集上展现出显著优势。实验二为超参数敏感性实验，验证了模型对关键超参数的鲁棒性与收敛性，说明该方法具备良好的调优空间与稳定性。实验三为消融实验，通过移除不同模块对模型性能的影响分析，进一步验证了各模块在整体性能中的重要性，强调了多分量建模与时空协同建模的必要性。

第四章 基于扩散模型的交通预测方法

4.1 引言

在交通预测任务中，不确定性建模是一个关键挑战。交通流量受天气、事故、道路封闭等复杂因素影响，呈现高度的波动性和不稳定性。因此，仅提供一个单一的预测值往往难以满足实际需求，模型还需要提供预测的可信度，即给出合理的置信区间，反映可能的波动范围。然而，传统的确定性模型通常忽略数据中的不确定性，仅输出单一预测值，导致模型在面对突发情况时预测可信度较低，缺乏对交通流异常变化的适应能力。

近年来，基于概率生成的扩散模型提供了一种有效的解决方案。扩散模型通过逐步添加噪声并在反向过程中去噪，可以有效学习数据分布的不确定性，使得模型不仅能输出点预测，还能提供完整的预测分布，从而量化交通流量的潜在波动范围。相比确定性方法，扩散模型能够更合理地刻画流量变化趋势，为交通调度和管理提供更可靠的决策支持。

为了解决不确定性建模的问题，本章提出了一种基于扩散过程的时空小波模型（Diffusion-based Spatio-Temporal Wavelet Model, DiffSTWave）。该模型结合了扩散建模和时空特征学习，通过以下核心机制提升预测精度并量化不确定性：

（1）引入扩散模型捕捉不确定性：本章沿用了文献^[45]的思想，采用扩散过程进行数据生成，使模型能够学习交通流量的潜在分布，并在预测时提供概率估计，而不仅仅是单点预测，从而提高预测的可信度。

（2）设计去噪网络贴合交通预测任务：扩散模型的核心在于去噪网络，本章在扩散模型的去噪网络中设计了一个时空解耦网络 STWaveNet 来对数据进行逐步去噪，得到预测噪声。通过去噪网络不仅提升了去噪过程的精度，还增强了模型对复杂交通数据的适应能力，使其能够在噪声还原的同时精准恢复真实的交通流模式。

（3）离散小波变换进行数据解耦：为了更好地捕捉时空数据中的复杂性，DiffSTWave 通过离散小波变换将数据分解为高频和低频成分，分别处理高频细节和低频趋势，从而避免了高频噪声对低频信号的干扰。这种数据解耦方法帮助模型更清晰地学习到时空数据中的重要模式，进而更准确地刻画预测结果的波动范围。

（4）时空建模增强依赖关系学习：本章在去噪网络中设计了时空块 STBlock，使得 DiffSTWave 能够同时处理空间和时间上的依赖关系。STBlock 结合了时间卷积网络和图卷积网络，使模型能够更全面地学习交通动态。

（5）不确定性量化：DiffSTWave 生成的不仅是未来流量的预测值，还提供相应的置信区间，使得预测结果更具可解释性，为智能交通管理提供更加稳健的信息支持。

本章主要介绍了 DiffSTWave 模型的相关理论及其在实验中的优秀性能。首先，第二

节详细介绍了适合于交通预测任务的条件扩散模型。接着，第三节重点介绍了模型的整体框架和各个关键模块及模块的设计与实现。第四节介绍了实验设置和数据集的情况，并通过一系列实验验证了本章的模型的有效性，同时与其他模型的预测效果进行了比较。最后，第五节对本章内容进行了总结，强调了本章的模型在解决交通流预测问题中的优势及其关键发现。

4.2 基于扩散过程的时空小波模型

4.2.1 模型框架

图 4-1 展示了 DiffSTWave 的整体框架，该模型首先在正向过程中将真实数据逐步加噪，最终得到一个近似于高斯分布的纯噪声；然后在反向过程中，通过去噪网络逐步还原该噪声，最终生成与真实数据分布一致的预测结果。

本章为 DiffSTWave 模型设计了专门的去噪网络 STWaveNet，以贴合交通预测任务。STWaveNet 负责在每个反向扩散步骤中估计和去除扰动数据中的噪声。具体而言，STWaveNet 首先对输入的噪声数据进行离散小波变换，将其解耦为高频分量和低频分量。解耦后的高低频数据分别输入到时空建模模块 STBlock 中，结合时间步与图结构作为条件信息，建模其时空相关性。同时，模型引入噪声等级嵌入机制，以增强对扩散步骤的感知能力。最后，将高频与低频分量的建模结果进行融合，输出用于还原原始数据的预测噪声。




图 4-1 DiffSTWave 整体框架

原始的扩散模型^[36]是一种无条件生成模型，它仅依赖于初始随机噪声生成样本。这种方法虽然在图像生成等任务中表现良好，但在实际应用中，特别是交通流量预测任务中，完全依赖噪声容易导致模式崩溃（Mode Collapse）问题，即生成的样本缺乏多样性，难以准确捕获交通数据的复杂时空分布。因此，为了更好地适用于交通预测任务，本文将扩散模型扩展为条件扩散模型（Conditional DDPM, CDDPM），引入历史交通数据和

图结构信息作为条件输入，使得模型能够更好地捕获数据的时空依赖性，从而提高预测精度并提升模型的可解释性。对于交通预测任务来说，历史交通数据是未来流量变化的重要条件信息。受文献^[45]启发，本章采用历史数据 x^{his} 和未来数据 x^{pre} 拼接作为目标数据 $x^{ta} = [x^{his}, x^{pre}] \in \mathbb{R}^{F \times V \times T}$, $T = t^{his} + t^{pre}$ ，并引入历史数据与未来数据的掩码拼接数据作为观测数据 $x^{ob} = [x^{his}, x_{msk}^{pre}] \in \mathbb{R}^{F \times V \times T}$ 以此来知道条件 DDPM 的去噪过程。

历史数据提供了交通流量的过去趋势信息，帮助模型理解数据分布的基本模式；而未来数据掩码可以明确标识哪些未来时间点需要预测，从而引导模型在预测阶段关注特定时刻的数据估计。这种拼接方式统一了历史的重建与未来的估计，使得模型能够同时建模历史与未来的信息，有效丰富了条件输入，从而减少了预测误差。

为了将扩散模型扩展为条件扩散模型，本章对反向过程进行了改进，使其能够基于观测数据和图结构进行噪声去除，重建目标分布。条件扩散模型的反向过程从高斯分布中采样目标数据，并且在每个时间步 t 使用去噪网络预测当前噪声并更新目标数据，具体过程可表示为式（4-1）。

$$p_{\theta}(x_{0:T}^{ta} | x^{ob}, G) = P(x_T^{ta}) \prod_{t=1}^T p_{\theta}(x_t^{ta} | x_{t-1}^{ta}, x^{ob}, G) \quad (4-1)$$

其中， θ 为去噪网络的参数。

训练过程中，条件扩散模型通过变分近似来优化目标，最小化真实逆向分布与模型学习到的分布之间的散度，目标是最小化负对数证据下界（Negative ELBO）。在引入条件信息后，式（2-23）的优化目标可进一步简化为式（4-2）。

$$\mathcal{L}(\theta) = \mathbb{E}_{x_{0:T}^{ta}, \epsilon} \|\epsilon - \epsilon_{\theta}(x_t^{ta}, t | x^{ob}, G)\|_2^2 \quad (4-2)$$

其中， ϵ_{θ} 是去噪网络。给定观测数据 x^{ob} ，目标数据 x_0^{ta} 以及图结构 G ，模型对噪声目标 $x_t^{ta} = \sqrt{\bar{\alpha}_t}x_0^{ta} + \sqrt{1 - \bar{\alpha}_t}\epsilon$ 进行采样，然后根据式（4-2）的损失函数对 ϵ_{θ} 进行训练，算法1总结了整个训练过程。

算法1 DiffSTWave 的训练过程

输入：训练数据的分布 $q(x^{ta})$

输出：训练去噪网络 ϵ_{θ}

1. Repeat
 2. $t \sim \text{Uniform}(1, \dots, T), \epsilon \sim \mathcal{N}(0, I), x_0^{ta} \sim q(x_0^{ta})$
 3. 根据观测数据构建 x^{ta}
 4. 计算 $x_t^{ta} = \sqrt{\bar{\alpha}_t}x_0^{ta} + \sqrt{1 - \bar{\alpha}_t}\epsilon$
 5. 进行梯度下降 $\nabla \theta \|\epsilon - \epsilon_{\theta}(x_t^{ta}, t | x^{ob}, G)\|_2^2$
 6. 直到收敛
-

推理过程中,条件扩散模型从标准高斯噪声开始,通过训练好的去噪网络逐步去噪,回复原始目标数据。在 x^{ob} 和 G 的指导下,每个去噪步骤的过程如式(4-3)所示。

$$p_{\theta}(x_{t-1}^{ta}|x_t^{ta},x^{ob},G)=\mathcal{N}\left(x_{t-1}^{ta};\mu_{\theta}(x_t^{ta},t|x^{ob},G),\sigma_{\theta}(x_t^{ta},t|x^{ob},G)\right) \quad (4-3)$$

其中, $\epsilon \sim \mathcal{N}(0,I)$ 为随机噪声。算法 2 描述了推理过程的中的每一步采样过程。

算法 2 DiffSTWave 的采样过程

输入: 历史图信号 x^{his} , 训练的去噪网络 ϵ_{θ} , 图结构 G

输出: 预测图信号 x^{pre}

1. 根据观测数据构 x^{ob}
2. $x_T^{ob} \sim \mathcal{N}(0,I), \epsilon \sim \mathcal{N}(0,I)$
3. For $t = T$ to 1 do
4. 根据式(4-3)对 x_{t-1}^{ta} 进行采样
5. End for
6. Return x^{pre}

4.2.2 去噪网络模块

在将扩散模型应用于交通预测时,如何将纯噪声有效还原为交通数据是一个关键问题。现有去噪方法通常采用 U-Net 结构或其他深度神经网络架构,利用卷积、跳跃连接等机制,在不同的尺度上提取特征,从而实现高效的噪声估计。U-Net 主要用于图像处理,采用编码—解码器结构进行特征提取和重建。U-Net 结构示意图如图 4-2^[66]所示。然而,交通数据具有强烈的时序依赖性,而 U-Net 采用的标准卷积和反卷积操作难以有效捕捉长期时间依赖,导致去噪后的数据缺乏合理的时序一致性。此外, U-Net 依赖全卷积网络,在处理高分辨率数据时计算复杂度较高,尤其是在长时间序列任务中,其计算开销和存储需求会迅速增长,降低了模型的效率和实用性。




图 4-2 U-Net 结构图

根据交通预测任务的特性，本章设计了时空解耦网络 STWaveNet。时空解耦网络 STWaveNet 将 x_t^{ta} , x^{ob} , t , G 作为输入，并输出预测噪声 ϵ 。其中， t 代表扩散过程中的步数， x_t^{ta} 表示目标结果在第 t 步加噪后的结果， x^{ob} 为观测到的历史数据， G 为交通路网的图结构信息。模型通过对输入数据的时空特征建模，生成对应的噪声估计值，从而为扩散模型的反向去噪过程提供指导。STWaveNet 网络中包含了数据解耦模块、时空模块、噪声等级嵌入模块与噪声融合和预测模块，各模块相互协作，共同构建高效的时空解耦网络。

4.2.3 数据分解模块

在时空解耦网络中，数据解耦的过程首先应用于扩散模型中的纯噪声。在扩散模型的训练过程中，噪声逐步添加到数据中，最终得到一个纯噪声的状态。在反向过程中，模型通过逐步去噪恢复到预测的噪声。为了避免噪声成分之间的相互干扰，尤其是在交通流量数据的时空特征上，解耦操作是通过多层离散小波变换（Discrete Wavelet Transform, DWT）^[67]来完成的。传统的解耦方法如经验模态分解（Empirical Mode Decomposition, EMD）^[68]可能会出现模态混叠的问题，即不同频率成分相互干扰，导致解耦结果不稳定。DWT 通过使用小波基函数进行分解，能够清晰地划分不同频率带的特征，从而避免了这种问题。这使得 DWT 在复杂时空数据中的应用更为可靠，尤其是在交通流量预测中，能够精确分离不同层次的时空特征，减少干扰。

同时，DWT 具有较低的计算复杂度，通常为 $O(N)$ ，相比于传统的傅里叶变换（Fourier Transform, FT）^[69]，DWT 在处理大规模数据时能够提供更高的计算效率。这对于交通流量预测尤为重要，因为交通数据通常是大规模且实时变化的，要求模型在处理数据时具备较强的实时性。DWT 的高效性使得其在大规模交通预测任务中表现得尤为出色，能够满足实际应用中的实时需求。

具体来说，离散小波变换是一种通过分解和重构信号来分析信号不同频率特性的重要工具。通过 DWT，可以将输入信号分解为不同尺度的近似系数和细节系数，分别对应信号的低频分量和高频分量，从而对信号的整体趋势和细节变化进行有效建模。之后，利用这些系数可以重建原始信号，确保信息无损还原。如图 4-3 所示，DWT 的分解过程是将输入信号 $x \in \mathbb{R}^t$ 通过低通滤波器 g 和高通滤波器 h ，分别得到低频分量 $x_{2,L}$ 和高频分量 $x_{1,H}$ ， $x_{2,h}$ 。低频分量代表信号的整体趋势，而高频分量则捕获信号中的局部细节变化。为了降低数据的冗余性和计算复杂度，滤波后的信号还会经过下采样操作，即保留每隔一个样本点的值，从而将数据量减少一半。分解过程可以表示为式（4-4）、（4-5）和（4-6）。

$$\bar{x}_{1,H} = (h \star x)_{(12)} \quad (4-4)$$

$$\bar{x}_{2,L} = (g \star (g \star x)_{(12)})_{(12)} \quad (4-5)$$

$$\bar{x}_{2,H} = (g \star (g \star x)_{(\downarrow 2)})_{(\downarrow 2)} \quad (4-6)$$

其中, $\star$ 表示卷积操作, $\downarrow 2$ 表示将滤波后的信号进行下采样。为了便于说明, 本节在此仅展示了两层 DWT 的分解过程。对于输入的交通流量时间序列, DWT 的过程能够提取出信号的多尺度特征, 为后续的时空建模提供基础。




图 4-3 离散小波变换两层分解过程示意图

由于 DWT 在分解过程中对信号进行了下采样, 导致分解后的数据长度减少。因此, 为了使分解后的信号与原始信号长度保持一致, 同时将不同频率的数据返回到时域, 通常需要使用逆离散小波变换 (Inverse Discrete Wavelet Transform, IDWT) 对信号进行重构。重构过程首先对近似系数和细节系数进行上采样, 即在每个样本点之间插入零值, 从而将数据量恢复至原始信号的长度。接着, 通过重构滤波器 g^T 和 h^T 对上采样后的信号进行滤波操作, 分别重建低频信息和高频细节。低频信息和高频细节随后被送入一个全连接神经网络模块, 映射到高维空间以便捕捉更复杂的特征。IDWT 与全连接模块的过程可表示式 (4-7) 和 (4-8)。

$$x_L = W^g g^T \star (g^T \star (x_{2,L})_{\uparrow 2})_{\uparrow 2} + b^g \quad (4-7)$$

$$x_H = W^h (g^T \star (h^T \star (x_{2,H})_{\uparrow 2})_{\uparrow 2} + h^T \star (x_{1,H})_{\uparrow 2}) + b^h \quad (4-8)$$

其中, $W^g, W^h \in \mathbb{R}^{F \times d}$ 和 $b^g, b^h \in \mathbb{R}^d$ 是可学习的参数, d 表示高维特征空间的维度。

通过上述分解与重构过程, DWT 和 IDWT 能够高效提取信号的不同特征, 并结合全连接模块生成高维表征, 为后续的交通流量预测提供强有力的支持。这种方式不仅保留了信号的关键信息, 还有效分离了不同频率的特征, 从而降低了高频与低频数据间的相互干扰, 提高降噪过程的效果, 进而提升模型的预测性能。

4.2.4 时空建模模块

在数据解耦后, 时空模块 (STBlock) 对高频和低频成分分别进行处理, 以捕捉交通数据中的时间和空间依赖性。时空模块首先利用时间卷积网络 (TCN) [52] 建模时间依赖性。TCN 通过因果卷积确保时间序列信息的传播符合因果性, 同时通过膨胀卷积扩展感受野, 使模型能够同时关注短期变化和长期趋势, 从而有效捕捉交通流中的多尺度时间特征。

此外, 时空模块还利用图卷积神经网络 (GCN) [70] 建模空间依赖性, 以学习不同交通传感器或区域之间的动态关系。由于交通流量具有较强的空间相关性, 不同区域的交

通状况往往相互影响, GCN 通过信息聚合机制使模型能够有效学习局部和全局的空间模式, 增强预测的准确性和稳定性。通过结合时间和空间信息, 时空模块能够充分挖掘交通流量数据中的复杂时空特征, 为后续的预测任务提供更具表达能力的特征表示。时空模块的具体模型如图 4-4 所示。




图 4-4 STBlock 结构示意图

（1）时间依赖性建模

TCN 旨在有效捕捉序列数据中的时间依赖性, 其中序列中的每个元素都依赖于过去的观察结果。通过应用因果卷积, TCN 可确保模型只访问当前和过去的信息, 同时避免任何未来数据泄漏。这一特性对于时间序列预测任务至关重要, 因为时间序列预测任务的主要目标是仅根据历史数据预测未来值。

此外, TCN 还提供并行计算功能, 与顺序递归操作相比, 可加快训练过程。这种计算效率使其能够有效地扩展到大型数据集, 而这正是交通预测任务中常见的情况。此外, TCN 的前馈架构避免了递归模型中经常出现的梯度消失和爆炸问题, 从而使训练动态更加稳定和稳健。

对于一个一维序列输入 $x \in R^T$ 以及一个滤波器 $f \in R^K$, 因果卷积操作在时间步 t 处的数学表达形式如式 (4-9) 所示。

$$x \star f(t) = \sum_{k=0}^K f(k)x(t-k) \quad (4-9)$$

X_H^t 和 X_L^t 可被分别表示为式 (4-10) 和式 (4-11)。

$$x_H^{conv} = \sigma(\eta \star x_H^t) \quad (4-10)$$

$$x_L^{conv} = \sigma(\eta \star x_L^t) \quad (4-11)$$

其中, η 是一个可学习参数, σ 是激活函数。

（2）空间依赖性建模

考虑到数据解耦带来的计算成本, 本节在空间建模中选择采用较为简洁高效的图卷积神经网络。尽管更加复杂的图神经网络结构, 如图注意力网络 GAT 或 GraphSAGE^[71], 在理论上能够提升空间特征提取能力, 但其计算开销也会显著增加, 不利于实时交通预测的高效性。由于模型已经包含基于扩散的框架和小波分解过程, 引入更复杂的图神经网络结构将进一步延长推理时间, 降低实时交通预测的实用性。

此外, 消融实验结果表明, 引入图卷积神经网络 GCN 模型已经显著提升了模型的

准确性，使其能够有效捕捉交通网络中的空间依赖关系。移除 GCN 模块会导致模型性能明显下降，进一步验证了其必要性。同时，进一步增加 GCN 结构的复杂性对预测精度的提升有限，反而会牺牲计算效率。因此，在保证模型高效性的同时，选用 GCN 作为空间特征建模的核心组件。

图卷积神经网络利用图的结构信息，通过卷积操作，将每个节点的特征与邻居节点的特征进行融合，从而生成新的节点表示。与传统卷积不同，GCN 在图结构上定义卷积操作，使得节点的特征表示能够在邻域信息的基础上不断增强。在 GCN 中，每一层的卷积操作可以理解为一个邻域特征聚合与更新的过程，即将节点特征通过加权聚合邻域信息进行更新。两层图卷积可以被表示为式 (4-12)。

$$f(X, A) = \sigma_1(\hat{A}\sigma_2(\hat{A}XW^0)W^1) \quad (4-12)$$

其中， X 是特征矩阵， A 是邻接矩阵，其中 $\hat{A} = \tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}$ 代表预处理矩阵， $\tilde{A} = A + I_N$ 是加上自环的邻接矩阵， I 是矩阵单位， $\tilde{D}$ 是度矩阵，其中， $\tilde{D}_{ii} = \sum_j (A + I)_{ij}$ 。 W^0 和 W^1 分别代表第一层和第二层的权重矩阵， σ_1 ， σ_2 代表激活函数，如 ReLU、LeakyReLU 等，用于引入非线性特性，使模型具备更强的表达能力。

由于邻接矩阵 A 可能导致特征在不同层次之间发生数值膨胀，因此引入了对称归一化的矩阵 $\tilde{A}$ ，通过 $\tilde{D}^{-\frac{1}{2}}$ 进行度归一化，使得特征聚合保持稳定性，防止特征在多层传播过程中失去稳定性。

GCN 通过多层卷积操作，不断在图结构上更新节点特征，逐步将局部邻域信息汇聚到节点表示中，最终生成包含全局拓扑信息的特征嵌入。图卷积神经网络的结构示意图如图 4-5 所示，直观地描绘了节点特征如何通过多层卷积进行更新，并最终形成增强后的特征表示。通过这一过程，GCN 使模型能够充分利用交通网络的拓扑信息，为流量预测提供更准确的空间特征表示。




图 4-5 两层 GCN 结构图

4.2.5 噪声等级嵌入

在扩散模型的反向过程中，不同的噪声级别 t 对预测噪声的影响不同，因此需要为噪声级别提供合理的表示，以帮助模型更好地学习去噪映射关系。为了标识编码噪声级别

信息，本节对噪声时间步 $t \in [1, T]$ 进行位置编码，并采用 Transformer^[54] 位置嵌入 (Positional Embedding) 进行处理，以便将时间步相关信息映射到高维空间，使模型能够更有效地感知不同时间步的噪声特性。具体而言，使用式 (4-13) 进行编码：

$$e(n) = [\dots, \cos(n/r^{\frac{-2d}{D}}), \sin(n/r^{\frac{-2d}{D}}), \dots]^T, \quad (4-13)$$

其中， $d = 1, 2, \dots, \frac{D}{2}$ 表示嵌入维度编号， r 是一个较大的常数，通常设为 10000。这种编码方式确保了噪声级别的嵌入具有平滑的连续性，同时不同时间步之间的表示具有唯一性，从而有助于模型学习不同去噪阶段的特征。此外，该方法通过固定的三角函数变换，使得不同时间步的嵌入具有一定的周期性，从而增强模型对时间信息的感知能力。

在模型中，噪声级别嵌入可以与其他输入特征结合，使得模型在不同噪声阶段都能学习到合适的去噪策略。通过这种方式，去噪网络能够准确区分不同时间步的特性，从而更稳定地生成高质量的预测结果。

4.2.6 噪声融合和预测

通过时空模块的低频信息和高频细节通过求和的方式进行融合，随后经过一个全连接层，以生成最终的预测噪声。模型输出的预测噪声采用四维张量的形式，具体表示为 (B, F, V, T) ，其中， B 表示批量大小 (Batch Size)，即一次训练或者推理过程中同时处理的样本数量。 F 对应交通流的特征维度 (Traffic Flow Features)，表示不同类型的交通流信息。 V 是图中的节点数 (Vertices)，即交通传感器的数量。 T 代表时间步长 (Time Steps)，即预测范围内的时间跨度。因此，预测噪声是一个四维张量，它在多个传感器、多个时间步和多个特征维度上捕捉了噪声信息，确保模型能够全面地描述交通流数据的不确定性。这种表示方式不仅保留了空间和时间结构，还能够通过噪声预测来辅助模型生成合理的未来交通流状态。

4.3 实验设计与结果分析

本节主要介绍实验的具体设置与分析，以验证所提出模型的有效性。首先，本节对实验环境、使用的数据集和参数配置进行描述，然后介绍评价指标，并通过实验结果分析模型的预测性能。

4.3.1 实验相关设置

(1) 实验环境配置

本实验在配备 24GB 显存的 Nvidia 3090 GPU 的计算环境中实现并运行 DiffSTWave 模型。实验采用 PyTorch 作为深度学习框架，并基于 CUDA 进行加速计算，以提高模型训练和推理的效率。此外，实验环境包括 Python 作为主要编程语言，并使用相关的科学

计算库进行数据处理和分析。

(2) 数据集信息

本节在三个真实交通数据集上 PeMS08、T-Drive^[26]和 Los-loop^[26]进行了实验，以评估 DiffSTWave 的有效性。表 4-1 详细总结了这些数据集的基本信息。

PEMS08 数据集来源于加利福尼亚州高速公路网络的道路传感器，包含 2018 年 7 月 1 日至 8 月 31 日期间的交通流量、占用率和速度等实时数据，覆盖 170 个关键位置的传感器点。

T-Drive 数据集由微软研究院发布，主要用于城市交通研究。该数据集记录了 2008 年 2 月 2 日至 2 月 8 日期间北京市出租车的 GPS 轨迹，并以二维网格 (Euclidean 结构) 的形式表示城市交通状况。

Los-loop 数据集则记录了 2012 年 3 月 1 日至 3 月 7 日期间洛杉矶地区高速公路的交通流信息，包括每 5 分钟采集一次的车速数据，这些数据由嵌入道路表面的感应线圈传感器收集。

表 4-1 数据集信息

Dataset	Node number	Time Step	Edge number
PeMS08	170	17856	295
T-drive	64	1767	481
Los-loop	207	2017	1095

(3) 实验参数设置

在模型训练过程中，模型使用了 Adam 优化器，初始学习率设置为 0.001，并采用每训练 5 轮后将学习率减半的策略，以帮助模型在训练后期更稳定地收敛。批量大小设定为 8。所有数据集按 6:2:2 的比例划分为训练集、验证集和测试集，在训练集上进行模型训练，同时在验证集上应用早停策略 (early stopping) 以防止过拟合。为了与先前研究保持一致，实验使用过去 1 小时的历史数据来预测未来 1 小时的交通流量变化。

在扩散模型的设置中，噪声水平 β_k 采用二次增长方案进行设定，其中初始噪声 β_1 设为 0.0001，最终噪声值 β_k 在 [0.1, 0.2] 范围内进行调节。扩散步骤数从 [50, 100, 200] 中选择，以便在不同的噪声水平下进行探索。这些设置和调优确保了模型在多个真实数据集上的稳定性和优越的预测性能。

(4) 评价指标

为了评估模型的预测性能，并比较预测值 $\hat{y}$ 与真实值 y 之间的差异，实验采用了 MAE、RMSE 和 CRPS 作为评价指标。这些指标能够全面反映模型的误差特征和不确定性表达能力，从多个角度衡量预测效果，同时帮助分析模型在不同场景下的适用性和稳定性，其中：

CRPS (Continuous Ranked Probability Score，连续排名概率评分) 是一种衡量概率分

布质量的指标，专门用于评估模型输出的概率分布与真实值的匹配程度。与传统的点预测误差指标不同，CRPS 能够评估模型对不确定性的建模能力，更加适用于概率预测任务。较低的 CRPS 值表明模型能够更准确地刻画数据的不确定性，从而提供更可靠的预测区间。CRPS 表达式如式（4-14）所示。

$$CRPS(F, y) = \int R(F(z) - I\{y \leq z\})^2 dz \quad (4-14)$$

其中， F 表示概率分布， $\{y \leq z\}$ 是一个指标函数，当 $y \leq z$ 时取值为 1，否则取值为 0。CRPS 值越小，说明模型的预测分布与真实分布的匹配程度越高，预测性能越优。

通过综合采用 MAE、RMSE 和 CRPS 三种评价指标，不仅能够评估模型的整体预测精度，还能分析其在不同误差类型下的表现，例如常规误差、极端误差以及概率分布拟合能力。此外，这些指标还可以帮助判断模型在不同数据集上的泛化能力，以及其不同交通流场景下的适用性。最终，这些评估结果能够为模型优化提供指导，确保模型在实际应用中具备更高的准确性、稳定性和适应性。

4.3.2 实验一：DiffSTWave 模型与经典预测模型的精度对比实验

本节通过对比多个基线模型，在不同数据集上评估 DiffSTWave 的预测性能，并分析其在不确定性建模和准确性方面的优势。本节选取确定性模型 ARIMA、T-GCN、GWN 模型与非确定性模型 TimeGrad、CSDI、DiffSTG 模型进行对比分析，以突出模型在确定性模型和非确定模型中都展现出优越性，其中：

ARIMA^[63]：整合移动平均自回归模型。实验中对交通流序列单独训练 ARIMA 模型，并使用 Akaike 信息准则选择最优的阶数组合。

T-GCN^[26]：结合图卷积网络和门控循环单元，实现了对交通路网的复杂拓扑结构和动态时间特性的联合建模。

GWN^[27]：结合图卷积网络和膨胀因果卷积，显著增强了模型的时空特征提取能力。

TimeGrad^[42]：基于扩散概率模型的自回归时间序列预测方法。通过梯度估计进行采样，提升概率预测性能。

CSDI^[43]：基于条件扩散模型的时间序列缺失值填充方法。利用观测数据相关性提升填充精度，并适用于插值和概率预测任务。

DiffSTG^[45]：非自回归的时空图预测框架，结合时空图和扩散模型，有效建模不确定性，提升预测准确性和稳定性。

表 4-2 对 DiffSTWave 与多个对比模型在 PeMS08、T-Drive、Los-Loop 三个数据集上的性能进行了全面比较。评估指标涵盖 MAE、RMSE 和 CRPS，这些指标覆盖了整个预测时间范围。

实验结果表明，DiffSTWave 在三个真实数据集上均表现出领先的性能，尤其是在概率预测能力方面表现更为突出。在 CRPS 指标上，DiffSTWave 全面优于其他主流概率模

型，充分体现了其在不确定性建模方面的卓越能力和稳定性。

表 4-2 DiffSTWave 模型与对比模型的性能比较

Method	PeMS08			T-drive			Los-loop		
	MAE	RMSE	CRPS	MAE	RMSE	CRPS	MAE	RMSE	CRPS
ARIMA	24.04	43.30	-	5.22	8.80	-	5.89	8.98	-
T-GCN	20.98	29.95	-	4.99	6.88	-	4.92	7.71	-
GWN	18.28	30.05	-	4.83	6.93	-	4.80	7.45	-
CSDI	32.11	47.40	0.11	5.35	6.94	0.30	6.31	8.71	0.11
DiffSTG	23.68	34.42	0.07	5.01	6.62	0.28	5.89	8.53	0.07
TimeGard	24.24	37.51	0.08	5.12	6.82	0.28	5.93	8.77	0.08
DiffSTWave	20.34	29.90	0.06	4.51	6.18	0.26	4.54	6.79	0.06

具体而言，与表现第二优的概率模型相比，DiffSTWave 在 CRPS 方面的提升幅度介于 7.1%至 14.3%，不仅体现了模型更强的概率分布拟合能力，也说明 DiffSTWave 能够更全面地覆盖可能的未来状态，提升预测结果的置信度。从建模机制来看，TimeGard 采用自回归方式，在长序列预测中易受误差累积影响，难以保证长期预测的稳定性，而 DiffSTWave 采用非自回归方式，能够在一步内生成完整的预测序列，有效降低误差传递带来的性能下降。

此外，CSDI 作为一种针对时间序列插值任务设计的模型，在完整序列的预测建模上并未取得理想效果。这说明在面对复杂的交通流预测问题时，仅依赖条件分数匹配而缺乏专门设计的时空建模机制，可能难以充分捕捉数据的动态变化。而 DiffSTG 虽然具备一定的扩散建模能力，但其直接在原始数据上建模，缺乏对不同频段特征的区分，在面对结构复杂、时空异质性强的交通数据时表现受到一定限制。DiffSTWave 模型可以更精准地捕捉短期动态变化和长期趋势信息，从而提升整体预测性能。这种细粒度建模策略也提高了模型的泛化能力，尤其在复杂交通情境中更为显著。

为了进一步根据数据集特征对模型优越性进行分析，本节对不同数据集上的概率模型的 MAE 值绘制了直方图。图 4-6 直观地证明，DiffSTWave 模型始终具有最低的 MAE，在 PeMS08 数据集上，DiffSTWave 模型较第二优模型 DiffSTG 降低了约 14.1%，显示其在处理周期性强且突发事件频发的高速公路传感器数据时，能够更稳定地捕捉交通流量趋势；在 T-drive 数据集上，DiffSTWave 模型比 DiffSTG 模型降低约 10.0%，这证明其在低采样率且空间分布稀疏的出租车轨迹数据场景中，依然能保持高精度；在 Los-loop 数据集上，DiffSTWave 模型较第二优模型 CSDI 降低约 28.0%，表明其对高峰与非高峰剧烈波动的高速环路数据具有强大的响应能力。

DiffSTWave 在三类异构数据集上均实现了最低 MAE，不仅验证了其在不同交通场景中的适应性，还进一步体现了小波分解与非自回归扩散联合框架在交通预测中的优越

性。未来可结合更多类型的交通传感器与外部事件数据，进一步提升模型的实用价值和泛化能力。




图 4-6 DiffSTWave 与对比模型的 MAE 比较

此外，即使在与确定性模型的对比中，DiffSTWave 依然展现出优秀的性能。在 PeMS08 数据集上，尽管 GWN 在 MAE 上略优于 DiffSTWave，但在 RMSE 这一衡量极端误差的重要指标上，DiffSTWave 明显更具优势。在 T-drive 和 Los-loop 数据集上，DiffSTWave 则在 MAE 指标上分别较次优模型降低 5.8%和 5.4%，全面优于所有确定性对比方法，进一步体现其在稳定性和准确性上的平衡能力。

综上所述，DiffSTWave 不仅在不确定性建模方面展现出显著优势，也在点预测精度上优于多个先进模型。其在不同类型交通数据上的稳健表现表明，DiffSTWave 是应对复杂交通预测任务的有效解决方案，具备广泛的实际应用前景。

4.3.3 实验二：DiffSTWave 模型的超参数实验

本节对 STBlock 层数和通道维度对预测精度的影响进行了系统性的超参数敏感性分析，并以 MAE 和 RMSE 作为主要的评价指标。




图 4-7 层数和通道数在 PeMS08 数据集上的影响

在 PEMS08 数据集上，通过实验结果可以观察到当模型采用 2 层 STBlock 且每层通道维度设置为 128 时，预测性能达到最佳，表现为最低的 MAE 和 RMSE，如图 4-7 所示。这表明在该数据集上，较深的时空建模结构和较宽的特征表示能力能够更充分地捕

捉复杂的交通模式和时空动态特征。

相较而言，在 T-drive 数据集上，模型在采用 1 层 STBlock 和 64 维通道配置时即可达到最优效果，如图 4-8 所示。进一步增加层数或通道维度并未带来性能提升，反而可能引入冗余建模和过拟合风险，导致精度下降。




图 4-8 层数和通道数在 T-Drive 数据集上的影响

这种超参数配置的差异，主要源于不同数据集在时空复杂性上的本质区别。PeMS08 数据集是一个具有高度空间结构复杂性和时间模式多样性的高速公路传感器数据集，对模型的时空表达能力提出了更高要求；因此，使用更深、更宽的模型结构能更好地适配其特征。而 T-drive 数据集作为出租车轨迹数据集，空间结构相对稀疏，轨迹具有较强的连续性和规律性，因此在较轻量的模型配置下即可实现良好预测。

这些实验结果强调了根据具体数据集特性灵活调整模型架构的重要性。模型的泛化能力不仅依赖于其表达能力，还受到任务场景复杂度的制约。通过合理选择 STBlock 的深度与通道维度，可以在准确性与计算效率之间取得更好的平衡，从而提升模型在实际应用中的实用性和鲁棒性。

4.3.4 实验三：DiffSTWave 模型的消融实验

在消融实验中，旨在系统地评估 DiffSTWave 模型中各关键模块的有效性，以及不同时间建模策略对整体预测性能的影响。通过逐步移除或替换模型中的核心组件，不仅可以量化各模块对性能的具体贡献，还能为模型的结构设计提供理论支撑和实践参考，从而指导未来的模型优化。以下是对各个实验设置的详细分析。

(1) 关键组件的有效性分析

本文在 T-drive 数据集上对 DiffSTWave 进行了消融实验，设计了三种衍生模型，分别对应对模型中解耦、空间建模与时间建模模块的移除。具体设置如下：

DiffSTWave-w/o-Decomposition: 移除离散小波变换模块，不对原始时空序列进行高低频解耦处理；

DiffSTWave-w/o-Spatial: 移除图卷积网络，不建模节点间的空间依赖关系；

DiffSTWave-w/o-Temporal: 移除时间建模模块，不建模历史数据中的时间动态信息；

DiffSTWave: 包含所有模块，作为对比的基准模型。

实验结果如图 4-9 所示，清晰地展现了各组件对模型预测性能的影响。首先，移除小波分解模块后，模型性能显著下降，MAE 和 RMSE 均明显上升。这表明，通过小波变换实现数据的频域解耦，对于充分提取高频突变和低频趋势信息具有重要作用，是模型预处理阶段的重要步骤。其次，去除图卷积网络后，评估指标出现明显下降，说明空间建模对于捕捉道路网络中节点之间的关联关系至关重要。在交通预测任务中，节点之间的空间依赖往往隐含着交通状态的传播规律，因此空间建模对提升预测精度有直接影响。移除时间建模模块后，模型性能下降最为显著，表明时间建模是交通预测任务中的核心环节。历史数据中的时间演化规律直接决定未来趋势的走向，忽略这一因素将导致预测能力的严重退化。




图 4-9 关键组件的有效性分析

总体而言，以上实验充分验证了 DiffSTWave 模型中各组件的独立价值与协同作用。无论是解耦的预处理机制、空间依赖的建模策略，还是时间序列的动态捕捉，都在不同维度上为模型性能的提升提供了关键支持。这些发现不仅验证了 DiffSTWave 模型设计的合理性，也为后续模块扩展和结构优化提供了重要理论依据和实验参考。

(2) 时间模型的选择

为评估时间建模模块对整体模型性能的影响，本节在 T-drive 数据集上设计并开展了一系列对比实验，比较了四种不同的时间建模方案，其核心差异如下：

DiffSTWave-w/o-Temporal: 移除时间建模模块，即不建模历史数据中的时间信息。

DiffSTWave-r/p-LSTM: 使用长短时记忆网络替代原始模型中的时间建模组件；

DiffSTWave-r/p-GRU: 使用门控循环单元替代原始模型中的时间建模组件；

DiffSTWave: 原模型，利用时间卷积网络分别对高频与低频特征建模，捕捉多尺度的时间依赖关系。

为了公平对比，本节仅替换时间建模部分，其余组件保持不变。实验结果如图 4-10 所示，主要反映出以下几点：

首先，在 MAE、RMSE 等评估指标上，DiffSTWave 均显著优于使用 LSTM 或 GRU

的替代模型，这充分说明了 TCN 在建模复杂时序依赖结构方面具备更强的表达能力。尽管 LSTM 和 GRU 是两种广泛使用的递归神经网络架构，它们在捕捉长距离依赖关系时通常会面临梯度消失或爆炸的问题，尤其在处理长序列时，可能导致模型训练困难和性能下降。GRU 相较于 LSTM 提供了更简洁的结构，但同样无法完全避免在长时依赖捕捉中的限制。此外，这些循环神经网络存在串行计算的瓶颈，使得计算效率较低，尤其在处理大量数据时，训练时间较长。尽管 TCN 在计算复杂度上略高于 LSTM 和 GRU，但其能够利用卷积层实现并行计算，避免了递归神经网络的梯度消失问题，且在捕捉长距离依赖关系和短时突变方面表现尤为突出，适用于交通流这类具有高动态波动特性的时序建模任务。TCN 作为非递归结构，具备良好的并行处理能力和稳定的梯度传播机制，提升了训练效率和精度。




图 4-10 不同时间模块的有效性分析

总而言之，实验结果进一步验证了 TCN 在 DiffSTWave 模型中的适用性以及高效性，提升了模型在时空学习任务中的表现。同时，强调了时间建模方式在交通预测任务中的重要性，也再次验证了 DiffSTWave 模型在建模复杂时间依赖结构、提升预测精度方面的优越性。

4.3.5 实验四：DiffSTWave 模型的交通预测曲线对比展示

为了更直观地评估不同方法在不确定性估计和预测准确性方面的表现，本节对其预测分布进行了可视化分析。具体而言，在 Los-loop 和 T-drive 两个真实交通数据集上，实验分别对比了 DiffSTG 与 DiffSTWave 所生成的预测分布。在图 4-11 中，展示了不同模型在时间维度上的预测分布情况，其中可以明显看出，DiffSTWave 模型更准确地刻画了数据的真实分布形态，其预测结果完全覆盖观测值，表现出更高的分布可靠性和模型稳定性，说明其在建模复杂交通动态时具有更强的表达能力。




图 4-11 DiffSTWave 模型与不确定性模型在 T-Drive 数据集节点 17 上的预测曲线对比

在图 4-12 中, 则进一步比较了两种模型在不确定性估计方面的表现。尽管 DiffSTG 模型和 DiffSTWave 模型均能覆盖真实观测值, 但 DiffSTWave 模型在预测区间上更具紧凑性, 其生成的预测分布带能够有效包络真实值波动轨迹, 同时展现出更小的采样方差。这表明模型在提高预测准确性的同时, 能够有效避免过宽的置信区间, 有效控制预测的不确定性, 从而在稳定性和实用性方面提供更强保障。




图 4-12 DiffSTWave 模型与不确定性模型在 Los-Loop 数据集节点 76 上的预测曲线对比

此外, 本节将 DiffSTWave 模型与多个传统的确定性模型进行了对比, 实验结果如图 4-13 所示。实验结果显示, 传统方法由于忽略了交通数据中固有的随机性和时空变化带来的不确定性, 往往只能提供点预测, 难以覆盖观测值的波动范围, 导致模型的鲁棒性不足。而 DiffSTWave 通过引入扩散模型对不确定性进行建模, 能够生成符合真实数据分布的样本, 显著提升了对未来交通状态的预测可信度和整体性能。




图 4-13 DiffSTWave 模型与确定性模型在 T-Drive 数据集节点 29 上的预测曲线对比图

4.4 本章小结

交通预测任务中通常伴随着突发事件，这些不确定因素显著增加了预测的复杂性与准确性的挑战。为此，本章引入了扩散模型，提出了一种新颖的概率预测框架 DiffSTWave，专为交通流预测问题设计。该模型融合了图神经网络在时空特征学习方面的强大能力与扩散模型在不确定性建模方面的优势，能够同时提升预测精度并实现可信的置信区间估计。

首先，本章阐述了 DiffSTWave 框架的设计理念，并针对交通预测场景对基础扩散过程进行了改造，引入条件扩散机制以适应学习任务的需求，结合具体定义和算法流程，系统展示了所提出方法的建模思路。

其次，提出了该框架的核心模块 STWaveNet，作为去噪网络以有效建模数据的复杂时空依赖关系。STWaveNet 通过引入离散小波变换对时序数据进行频域解耦，将输入划分为相互独立的高频与低频分量，分别建模其时空特性。为进一步增强建模能力，网络中设计了 STBlock 模块，以确保对时序趋势与空间结构的联合刻画。

最后，本章设计并开展了四组实验以验证模型的有效性与适应性：实验一为与现有主流方法的性能对比，验证了 DiffSTWave 在多个数据集上的预测优势；实验二为超参数敏感性实验，探讨关键参数对模型性能的影响；实验三为模块消融实验，分析各个子模块在整体性能中的贡献；实验四为预测曲线可视化对比实验，直观展示了模型的预测置信区间相较于确定性方法在实际场景中的表现。实验结果表明，DiffSTWave 不仅具备先进的预测能力，还能输出合理的不确定性估计，为高风险场景提供重要决策支持。

第五章 总结与展望

5.1 总结

在城市快速化发展的今天，交通系统的高效运转已成为城市管理的重要课题。随着城市规模的不断扩大和车辆数量的激增，传统的交通管理方式面临巨大挑战，迫切需要借助先进技术实现对交通状况的实时感知与精准预测。当前，交通预测不仅要求对常规流量进行准确估计，更需要及时捕捉突发事件和异常流量带来的影响，以便实现动态调整 and 高效指挥。

在这一背景下，交通预测技术逐渐从单一的统计方法演进为多源数据融合、深度学习驱动的智能预测。早期基于历史数据和简单数学模型的预测方法，在面对城市交通的复杂性时显得力不从心。近年来，随着大数据、人工智能以及物联网技术的蓬勃发展，研究者们开始利用深层神经网络、图模型等先进方法，尝试捕捉交通流量中的时空特征和非线性变化规律。然而，交通数据中固有的噪声和不确定性仍然是提高预测准确率的瓶颈，这也促使研究者探索能够更好地处理数据噪声与分布不确定性的全新建模思路。

新一代预测模型正是在这种需求背景下应运而生，它们通过模拟数据演化过程，采用生成式方法对复杂交通状态进行建模，从而在预测过程中不仅输出精细的数值预估，还能对预测结果的不确定性进行量化。这种基于生成模型的思路为交通预测带来了突破性的进展，使得模型在应对突发事件和异常状态时具备更强的鲁棒性和适应能力。本研究正是在上述背景下展开，旨在通过构建一种基于扩散机制的时空预测模型，实现对交通流动态变化的精准捕捉，并为城市交通管理提供决策支持。

本论文的主要贡献可以归纳为两大部分：一是对交通预测领域相关基础理论的系统梳理和总结；二是提出了两个新型的交通预测模型，并对其设计理念、技术细节和实际应用效果进行了深入探讨。

在基础理论方面，论文详细回顾了城市交通预测的发展历程，探讨了交通数据的时空特性、不确定性问题及时空信息的提取方法。通过对传统统计模型和现代深度学习方法的比较分析，论文揭示了现有方法在捕捉时空依赖关系以及量化预测不确定性方面的不足，为后续模型设计提供了坚实的理论支撑和创新方向。

同时，本文构建了多分量时序图神经网络 MTGNN 模型，该模型通过先对交通数据进行季节趋势分解，有效地将原始数据拆解为长期趋势和短期季节性波动两部分。针对趋势部分，模型利用时间卷积网络与图注意力网络联合作用，重点捕捉数据中的长期时空依赖性；而针对季节性波动部分，则采用傅里叶注意力机制结合图注意力网络，以精准反映数据的周期性变化。这样一来，MTGNN 模型能够分别针对不同频率的信息进行独立建模，避免了两种特征之间的干扰，从而显著提升了交通预测的准确性和稳定性。

通过在四个真实交通数据集上进行对比, MTGNN 模型在所有数据集上均表现出优越的预测性能, 尤其在 MAE 和 MAPE 指标上取得了显著提升。

在 MTGNN 的基础上, 基于扩散过程的时空小波 DiffSTWave 模型进一步引入了扩散机制, 通过对数据的分解和噪声模拟, 提升了模型在不确定性量化方面的能力。模型首先采用离散小波变换将交通数据分解为高频和低频信息, 并通过时间卷积网络对高低频特征进行建模, 同时结合图卷积网络提取空间依赖性。在扩散过程的反演阶段, DiffSTWave 模型逐步还原数据, 生成符合真实分布的预测结果, 从而在提高预测精度的同时, 量化了交通流量的潜在不确定性。通过实验证明, DiffSTWave 模型在与其他基于扩散的概率模型比较时, 将连续排名概率评分 (CRPS) 降低了 7.1%–14.3%, 充分证明了其生成更可靠交通预测结果的能力。

MTGNN 模型与 DiffSTWave 模型不仅在实验验证中展现出优越性能, 还具备良好的实际部署潜力, 能够支持多种智能交通应用场景。具体而言, 在信号控制中, MTGNN 模型能够通过预测未来流量变化, 优化红绿灯配时策略, 实现多路口协同控制, 缓解局部拥堵; 在路径规划中, 其动态预测能力可避免高峰拥堵路段, 提供最优行驶路径; 在交通调度中, MTGNN 能够预测客流高峰, 优化公交、地铁等公共交通资源分配, 提升出行效率。

相比之下, DiffSTWave 模型在复杂与高风险交通场景下更具优势。在智能交通信号控制方面, DiffSTWave 能够识别突发事件导致的交通异常, 并动态调整信号灯策略; 在路径规划中, 其不确定性量化能力帮助识别高风险区域, 提供更安全高效的行驶路线; 在交通调度中, DiffSTWave 能够预测多时间步长的交通流演变, 并量化潜在风险, 辅助管理部门制定更合理的应急与资源分配方案。

整体来看, MTGNN 与 DiffSTWave 模型分别从时空解耦建模与扩散机制建模两个视角切入, 不仅提升了交通预测的精度, 也为应对交通流数据的复杂性和不确定性提供了新的研究范式。这两种模型在功能上相辅相成: MTGNN 更专注于捕捉周期性与长短期趋势, 适合常规信号控制与路径优化; 而 DiffSTWave 更擅长建模不确定性, 在事故多发区域与复杂交通环境下更具表现力与适应性。随着智能交通基础设施的不断完善, 这两种模型有望在智能交通信号控制、路径优化、应急调度等核心领域发挥更大的作用, 为智慧城市的发展注入新的活力与动能。

5.2 展望

尽管模型在交通预测方面展现了显著优势, 但仍存在一些不足之处。首先, 当前模型在推理阶段的计算复杂度较高, 导致预测速度较慢, 尚未完全满足实时交通管理的需求。其次, 模型结构较为复杂, 参数量较大, 对计算资源的要求较高, 在实际部署过程中可能会遇到资源限制问题。未来的工作可以从以下几个方向进行改进:

(1) 针对推理时间过长的问题,可以探索更加高效的网络结构和特征提取方法,尝试引入模型压缩、剪枝或量化等技术,以降低模型复杂度和加快计算速度。

(2)通过设计轻量化模型和利用高性能计算平台,进一步提高模型的实时预测能力,使其更适合应用于实际交通管理场景。

(3)在模型训练过程中引入更多样化的交通数据,并采用自适应学习策略,提升模型在不同交通环境下的鲁棒性和泛化能力。

(4)未来研究还应关注模型内部机制的可解释性,帮助决策者更好地理解模型预测结果,从而更有效地应用于交通调度和管理决策中。

通过以上改进措施,期望能够进一步提升模型在实际应用中的性能和适应性,为城市交通预测与管理提供更为高效、精准的技术支持。

参考文献

- [1] 公安部. 全国机动车保有量达四点五三亿辆[N]. 人民公安报, 2025-01-18(004).
- [2] 交通运输部. 2023 年交通运输行业发展统计公报[N]. 中国交通报, 2024-06-18.
- [3] 百度地图. 2023 年度中国城市交通报告[EB/OL]. <https://jiaotong.baidu.com>, 2024-03-29.
- [4] Zhang J P, Wang F Y, Wang K F, et al. Data-Driven Intelligent Transportation Systems: A Survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2011, 12(4): 1624-1639.
- [5] 冯凤江, 杨增刊. 基于图卷积和注意力机制的高速公路交通流预测[J]. 公路交通科技, 2023, 40(9): 215-223.
- [6] 张韞, 张波, 王剑楠, 等. 基于动态时空特征周期性编码的公路交通流量预测模型[J]. 公路交通科技, 2025, 42(03): 21-33.
- [7] Yang H, Li Z, Qi Y. Predicting traffic propagation flow in urban road network with multi-graph convolutional network[J]. Complex & Intelligent Systems, 2024, 10(1): 23-35.
- [8] 汤春文, 苑文颖. 高速公路噪声预测评价与声屏障设计[J]. 公路, 2023, 68(04): 255-262.
- [9] 吴家成, 王洪钰, 肖建力. 面向区域交通状态预测的时空集成模型[J]. 上海理工大学学报, 2021, 43(05): 474-483. DOI: 10.13255/j.cnki.jusst.20201230006.
- [10] 张红, 杨俊译. 用于异常交通流预测的时空生成对抗聚类图卷积网络[J/OL]. 计算机工程, 1-14[2025-04-03]. <https://doi.org/10.19678/j.issn.1000-3428.0070180>.
- [11] Miao Y, Bai X, Cao Y, et al. A novel short-term traffic prediction model based on SVD and ARIMA with blockchain in industrial internet of Things[J]. IEEE Internet of Things Journal, 2023, 10(24): 21217-21226.
- [12] Chang S Y, Wu H C, Kao Y C. Tensor extended Kalman filter and its application to traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(12): 13813-13829.
- [13] Rajeh T M, Li T, Li C, et al. Modeling multi-regional temporal correlation with gated recurrent unit and multiple linear regression for urban traffic flow prediction[J]. Knowledge-Based Systems, 2023, 262: 110237.
- [14] Yu B, Song X, Guan F, et al. k-Nearest neighbor model for multiple-time-step prediction of short-term traffic condition[J]. Journal of Transportation Engineering, 2016, 142(6): 04016018.
- [15] Feng X, Ling X, Zheng H, et al. Adaptive multi-kernel SVM with spatial-temporal correlation for short-term traffic flow prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 20(6): 2001-2013.
- [16] Yuan H, Li G. A survey of traffic prediction: from spatio-temporal data to intelligent transportation[J]. Data Science and Engineering, 2021, 6(1): 63-85.
- [17] 温志勇, 翁小雄, 谢帮权. 基于多层复杂网络的循环神经网络交通量预测模型[J]. 现代电子技术

- 术,2024,47(22):173-178.DOI:10.16652/j.issn.1004-373x.2024.22.027.
- [18] Ounoughi C, Yahia S B. Sequence to sequence hybrid Bi-LSTM model for traffic speed prediction[J]. Expert Systems with Applications, 2024, 236: 121325.
- [19] Raut A, Maurya M K, Chaurasiya V K, et al. Adaptive hyperparameter optimization for short term traffic flow prediction with spatial temporal correlated raster data[J]. Evolving Systems, 2024, 15(2): 469-488.
- [20] Bhaumik K K, Niloy F F, Mahmud S, et al. STLGRU: Spatio-temporal lightweight graph GRU for traffic flow prediction[C]//Pacific-Asia Conference on Knowledge Discovery and Data Mining. Singapore: Springer Nature Singapore, 2024: 288-299.
- [21] Zhang J, Xu X, Xiao F. STBGRN: a traffic prediction model based on spatiotemporal bidirectional gated recurrent units and graph convolutional residual networks[J]. International Journal of Computational Intelligence Systems, 2024, 17(1): 125.
- [22] Lv Z, Xu J, Zheng K, et al. Lc-rnn: A deep learning model for traffic speed prediction[C]//IJCAI. 2018, 2018: 27.
- [23] Harrou F, Zeroual A, Kadri F, et al. Enhancing road traffic flow prediction with improved deep learning using wavelet transforms[J]. Results in Engineering, 2024, 23: 102342.
- [24] 李帅,杨柳,赵欣卉.基于深度学习的城市区域短时交通拥堵预测算法[J].科学技术与工程,2023,23(25):10866-10878.
- [25] Scarselli F, Gori M, Tsoi A C, et al. The Graph Neural Network Model[J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61-80.
- [26] Zhao L, Song Y J, Zhang C, et al. T-GCN: A Temporal Graph Convolutional Network for Traffic Prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(9): 3848-3858.
- [27] Wu Z, Pan S, Long G, et al. Graph wavenet for deep spatial-temporal graph modeling[J]. arXiv preprint arXiv:1906.00121, 2019.
- [28] Fang Z, Long Q, Song G, et al. Spatial-temporal graph ode networks for traffic flow forecasting[C]//Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 2021: 364-373.
- [29] Minka T. Bayesian linear regression[R]. Technical report, MIT, 2000.
- [30] Aigrain S, Foreman-Mackey D. Gaussian process regression for astronomical time series[J]. Annual Review of Astronomy and Astrophysics, 2023, 61(1): 329-371.
- [31] Jospin L V, Laga H, Boussaid F, et al. Hands-on Bayesian neural networks—A tutorial for deep learning users[J]. IEEE Computational Intelligence Magazine, 2022, 17(2): 29-48.
- [32] Gal Y, Ghahramani Z. Dropout as a bayesian approximation: Representing model uncertainty in deep learning[C]//international conference on machine learning. PMLR, 2016: 1050-1059.
- [33] Doersch C. Tutorial on variational autoencoders[J]. arXiv preprint arXiv:1606.05908, 2016.
- [34] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of

- the ACM, 2020, 63(11): 139-144.
- [35] Yang L, Zhang Z, Song Y, et al. Diffusion models: A comprehensive survey of methods and applications[J]. ACM Computing Surveys, 2023, 56(4): 1-39.
- [36] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
- [37] Lugmayr A, Danelljan M, Romero A, et al. Repaint: Inpainting using denoising diffusion probabilistic models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 11461-11471.
- [38] Guo L, Wang C, Yang W, et al. Shadowdiffusion: When degradation prior meets diffusion model for shadow removal[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 14049-14058.
- [39] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.
- [40] Wu T, Fan Z, Liu X, et al. AR-Diffusion: Auto-regressive diffusion model for text generation[J]. Advances in Neural Information Processing Systems, 2023, 36: 39957-39974.
- [41] Li X, Thackstun J, Gulrajani I, et al. Diffusion-LM improves controllable text generation[J]. Advances in Neural Information Processing Systems, 2022, 35: 4328-4343.
- [42] Rasul K, Seward C, Schuster I, et al. Autoregressive denoising diffusion models for multivariate probabilistic time series forecasting[C]//International conference on machine learning. PMLR, 2021: 8857-8868.
- [43] Tashiro Y, Song J, Song Y, et al. CSDI: Conditional score-based diffusion models for probabilistic time series imputation[J]. Advances in neural information processing systems, 2021, 34: 24804-24816.
- [44] Yuan X, Qiao Y. Diffusion-ts: Interpretable diffusion for general time series generation[J]. arXiv preprint arXiv:2403.01742, 2024.
- [45] Wen H, Lin Y, Xia Y, et al. DiffSTG: Probabilistic spatio-temporal graph forecasting with denoising diffusion models[C]//Proceedings of the 31st ACM International Conference on Advances in Geographic Information Systems. 2023: 1-12.
- [46] Zhang S, Wang S, Tan X, et al. Sasdim: Self-adaptive noise scaling diffusion model for spatial time series imputation[J]. arXiv preprint arXiv:2309.01988, 2023.
- [47] Hu J, Liu X, Fan Z, et al. Towards unifying diffusion models for probabilistic spatio-temporal graph learning[C]//Proceedings of the 32nd ACM International Conference on Advances in Geographic Information Systems. 2024: 135-146.
- [48] 户佐安, 邓锦程, 韩金丽, 等. 图神经网络在交通预测中的应用综述[J]. 交通运输工程学报, 2023, 23(05): 39-61. DOI:10.19818/j.cnki.1671-1637.2023.05.003.

- [49] 张杰.融合交通领域知识与深度学习的城市快速路交通状态估计与预测[D].浙江大学,2023.DOI:10.27461/d.cnki.gzjdx.2023.000094.
- [50] Cui H, Meng Q, Teng T H, et al. Spatiotemporal correlation modelling for machine learning-based traffic state predictions: state-of-the-art and beyond[J]. Transport reviews, 2023, 43(4): 780-804.
- [51] Guo S, Lin Y, Feng N, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 922-929.
- [52] Bai S, Kolter J Z, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.
- [53] Shi X, Qi H, Shen Y, et al. A spatial-temporal attention approach for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(8): 4909-4918.
- [54] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [55] Caliendo M, Kopeinig S. Some practical guidance for the implementation of propensity score matching[J]. Journal of economic surveys, 2008, 22(1): 31-72.
- [56] Vincent P, Larochelle H, Bengio Y, et al. Extracting and composing robust features with denoising autoencoders[C]//Proceedings of the 25th international conference on Machine learning. 2008: 1096-1103.
- [57] Zhang X, Jin X, Gopalswamy K, et al. First de-trend then attend: Rethinking attention for time-series forecasting[J]. arXiv preprint arXiv:2212.08151, 2022.
- [58] Yu Q, Ding W, Zhang H, et al. Rethinking Attention Mechanism for Spatio-Temporal Modeling: A Decoupling Perspective in Traffic Flow Prediction[C]//Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. 2024: 3032-3041.
- [59] Brigham E O. The fast Fourier transform and its applications[M]. Prentice-Hall, Inc., 1988.
- [60] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arxiv preprint arxiv:1710.10903, 2017.
- [61] Fang Y, Qin Y, Luo H, et al. When spatio-temporal meet wavelets: Disentangled traffic forecasting via efficient spectral graph attention networks[C]//2023 IEEE 39th international conference on data engineering (ICDE). IEEE, 2023: 517-529.
- [62] Hamilton J D. Time series analysis[M]. Princeton University Press, 2020.
- [63] Williams B M, Hoel L A. Modeling and forecasting vehicular traffic flow as a seasonal ARIMA process: Theoretical basis and empirical results[J]. Journal of Transportation Engineering, 2003, 129(6): 664-672.
- [64] Wu C H, Ho J M, Lee D T. Travel-time prediction with support vector regression[J]. IEEE Transactions on Intelligent Transportation Systems, 2004, 5(4): 276-281.
- [65] Jiang J, Han C, Zhao W X, et al. Pdformer: Propagation delay-aware dynamic long-range transformer

- for traffic flow prediction[C]//Proceedings of the AAAI conference on artificial intelligence. 2023, 37(4): 4365-4373.
- [66] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer international publishing, 2015: 234-241.
- [67] Heil C E, Walnut D F. Continuous and discrete wavelet transforms[J]. SIAM review, 1989, 31(4): 628-666.
- [68] Huang H, Chen J, Sun R, et al. Short-term traffic prediction based on time series decomposition[J]. Physica A: Statistical Mechanics and its Applications, 2022, 585: 126441.
- [69] Sifuzzaman M, Islam M R, Ali M Z. Application of wavelet transform and its advantages compared to Fourier transform[J]. 2009.
- [70] Wu F, Souza A, Zhang T, et al. Simplifying graph convolutional networks[C]//International conference on machine learning. Pmlr, 2019: 6861-6871.
- [71] Liu J, Ong G P, Chen X. GraphSAGE-based traffic speed forecasting for segment network with sparse data[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23(3): 1755-1766.